

设计文档

初审提交版 (2026-09-03 冻结) | 数据截至 2026-09-03 快照 | 基线 develop @ e7ce146e

本文档为系统的整体设计方案，作为开发实施的单一事实源。执行计划与分工见 [执行计划.md](#)。


目录

- 项目概览
- 项目背景与目标
- 总体技术架构
- 项目时间节点
- 数据采集与预处理
- 知识图谱构建
- 大模型应用策略
- 动态演化与新岗位发现
- 简历解析
- 人岗匹配算法
- 前端可视化
- 系统架构与部署
- 账户与权限系统
- 测试与质量保障
- 测试用例矩阵
- 风险与应对预案
- 合规与伦理保障
- 验收标准

详细团队分工与执行计划见 [执行计划.md](#) (执行计划)

0. 项目概览

0.1 系统总览



团队分工: 详见 [执行计划.md](#) 第 1.2 节。6 人分六模块——前端 (黄唐尧)、后端 (马兴达)、算法 (张恺天)、数据 (刘琪)、测试 (王鹏羽)、文档 (张怀伟)。

0.2 核心创新点

创新点	实现方式	对应模块
多源交叉验证	跨源一致性由 cross_validate_jds 每日计算并写回快照、前端可视化；「≥2 独立源印证后入图」硬门控列入后续路线图；当前按「每日计算并展示跨源一致性」口径落地	算法研发
幻觉防控三道防线	① JSON Schema 强校验 ② 跨源交叉验证 ③ 白名单 + O*NET 对齐	算法研发
证据驱动匹配	每条匹配断言附带 evidence_id，前端可点击追溯至原始 JD/论文	算法 + 前端
图谱可视化	ECharts 2D 力导向图为主，react-force-graph-3d (Three.js/WebGL) 作为可选 3D 模式，4 种视图切换	前端开发
静默 Token 续期	JWT 双 Token + Axios interceptor 自动捕获 401 刷新，用户无感	后端开发
AI 流水线调度	系统 cron 编排每日 ETL + ARQ 异步任务队列处理耗时计算	后端 + 数据
技能演化追踪	90 天滑动窗口 + 版本快照 + Graph Version Diff，可回溯任意历史版本	算法研发

0.3 关键技术决策

选型	替代方案	选择理由
Vite + React 19	Vue 3 / Next.js	3D 图谱库 react-force-graph-3d 生态最佳（作为可选模式）
OpenAI 兼容 API（讯飞星火 / Qwen / GPT / DeepSeek 等）	GPT-4 / 文心	统一 OpenAI 接口 + provider 可切换
Neo4j 5	ArangoDB / JanusGraph	Cypher 社区成熟 + 全文索引（cjkc）+ 图算法生态（GDS 可扩展）
FastAPI	Flask / Django	异步原生 + Pydantic 校验 + OpenAPI 自动生成
ECharts + react-force-graph-3d（可选）	G6 / D3.js	2D 力导向图为主，3D 模式可选启用

关键决策：

- 前后端通过接口契约协作：.yaml 契约文件先行约定 → 前后端并行开发 → 契约测试验证一致性
- 前端 Token 维护策略：access_token 与 refresh_token 均存前端内存变量（access 经请求拦截器注入 Authorization: Bearer；refresh 经请求体发送 /auth/refresh），refresh_token 同时由后端 Set-Cookie 写入 httpOnly Cookie（httponly + samesite=lax，生产启用 Secure），页面刷新后前端调用 /auth/refresh 利用 Cookie 无感恢复会话；Axios interceptor 捕获 401 自动续期（并发请求共享刷新 Promise，成功后重放原请求），刷新失败清理本地状态并跳转 /login
- 长耗时任务异步化：简历解析、匹配计算等耗时操作通过 ARQ 异步队列处理，前端轮询 task_id 获取结果
- 图谱渲染策略：默认 2D 力导向图（ECharts），3D 模式（react-force-graph-3d）作为可选增强，WebGL2 不可用时自动降级至 2D
- LLM 多 provider 同步重试链：放弃本地 Ollama fallback（CPU 推理 30-60s 与超时阈值冲突 + GPU 硬件不确定），改用多 provider 同步重试链（在 configs/llm_providers.yaml 中配置、不限定厂商，后续支持管理员前端调整）。同步路由超时即报错（10s 上限），异步任务按优先级依次尝试（90s 上限）
- FastAPI 同端口托管前端：移除 Nginx，FastAPI 通过 StaticFiles 挂载前端构建产物，中间件承担 CORS/CSP/HSTS/gzip。服务数从 6 降为 4（api/postgres/redis/neo4j）
- 压测决定验收标准：M3 初（8/06-8/08）统一基准压测 panorama/Neo4j Cypher/全文检索/pgvector 四类 P95 指标，按分档预案处理（达标保留 / 500ms-1s 调整为 < 1s / > 1s 优化查询）。压测报告作为验收标准最终依据

1. 项目背景与目标

1.1 项目意义与社会价值

本项目响应国家从"人口红利"向"人才红利"转型的战略需求。在"新质生产力"与"人工智能+"行动的双轮驱动下，以新一代信息技术为核心的数字经济正深刻重塑产业格局。然而，技术迭代速度远超人才培养周期——大模型、Agent、RAG 等方向每季度涌现新范式，而高校专业培养以 4 年为周期，导致**结构性供需错配**日益严峻。

本系统的社会价值体现在三个层面：

- 对求职者**：打破"不知道学什么"的信息壁垒，以技能级全景图谱指引职业发展方向，提供个性化学习路径规划，让新兴领域青年与新就业形态劳动者有据可依。
- 对企业**：解决"招不到合适的人"的困境，通过动态感知技术趋势，提前识别新兴岗位需求，降低招聘与培养成本。
- 对行业**：构建可自我进化的"人才能力大脑"，实现从"静态画像"到"动态感知"的跨越，为数字经济时代的人才战略提供科学基础设施。

1.2 行业痛点

当前招聘市场面临四大核心矛盾：

- 结构性供需错配**：技术迭代速度（AI/大模型每季度出现新方向）远超高校人才培养周期（4年本科），企业「招不到合适的人」与青年「不知道学什么」并存。
- 数据时滞与噪声**：招聘JD普遍存在滞后（沿用3年前的要求）、抄袭（同质化严重）、通胀（虚高要求），传统关键词匹配无法感知真实技术趋势。
- 能力幻觉风险**：大模型在生成岗位定义和技能抽取时易虚构技能项，缺乏科学性与可追溯性，直接损害图谱公信力。
- 匹配粗放**：传统人岗匹配仅停留在「关键词命中」层面，缺乏细粒度（技能点级）的差距诊断与个性化的学习路径规划。

1.3 系统目标

构建一套**可追溯、可验证、可动态更新**的「人才能力大脑」，以证据节点为核心，实现以下六项能力：

岗位范围：立足数字经济发展，聚焦新一代信息技术领域（围绕人工智能、大数据、智能系统、物联网等），兼顾国际国内数据对比。

能力	描述	量化目标
新岗位发现	基于多源趋势监测，提前识别产业化拐点，定义新兴岗位	候选岗位置信度 ≥ 0.8
能力动态演化	90天滑动窗口追踪技能频次变化，自动识别新兴/衰退技能	版本快照按需可回溯
图谱可视化	2D 力导向图为主（3D 可选），展示岗位-技能-证据关系，四种视图切换	≥ 100 节点 @ 60fps, ≥ 200 节点 @ 30fps
简历解析	支持PDF/Word/图片，大模型结构化抽取	准确率 $\geq 90\%$
人岗匹配	四维加权 (BT v4: 技能/经验/学历) + 差距分析 + 学习路径推荐	准确率 $\geq 90\%$ (实测 0.9714)
证据追溯	每条技能断言挂载证据节点，端到端可追溯	引用覆盖率 100%

1.4 非功能需求规格

本节系统化整合散见于各章的非功能需求指标，作为验收与压测的统一基线。

1.4.1 性能需求

压测验证说明：以下 P95 指标为目标值，最终验收值以统一基准压测结果为准。压测覆盖 panorama 端点、Neo4j Cypher 查询、Neo4j 全文检索、pgvector 向量检索四类场景，使用 Locust 100 并发。压测结果按分档预案处理：P95 达标则保留原指标；500ms-1s 区间内调整为 < 1s；> 1s 需优化查询或调整 limit 默认值。压测报告写入 docs/perf_baseline_{date}.md，验收标准随之同步更新。

场景	指标	目标值	验证方法
图谱 3D 渲染	帧率	≥100 节点 @ 60fps；≥200 节点 @ 30fps	Chrome DevTools Performance
同步 API 查询	P95 响应时间	< 500ms（待压测验证）	Locust 100 并发压测
图谱 panorama 端点	P95 响应时间	< 500ms（300s Redis TTL 缓存命中后 < 100ms；管理端图编辑/审核路径即时失效）	Locust 100 并发压测
匹配推理（单岗位）	P95 响应时间	≤ 2s	Locust 100 并发压测
批量推荐（全量岗位）	P95 响应时间	≤ 5s（异步任务）	ARQ 任务计时
pgvector 向量检索	P95 延迟	< 300ms（待压测验证）	pgvector EXPLAIN ANALYZE + Locust
Neo4j Cypher 查询	P95 延迟	< 500ms（待压测验证，超阈值触发优化）	图谱查询日志 + Locust
Neo4j 全文检索	P95 延迟	< 500ms（待压测验证）	Neo4j PROFILE + Locust
预计算缓存命中	响应时间	< 100ms	Redis 监控
并发承载	100 并发错误率	< 1%	Locust 压测
接口限流	普通 / LLM	100 req/min / 10 req/min	令牌桶中间件
数据采集	单日 JD 采集量	P0 ≥ 100 条/日，P1 ≥ 200 条/日	ARQ 仪表盘

1.4.2 可用性需求

指标	目标值	实现方式
LLM API 可用性	主 API 故障自动切换	多 provider 同步重试链（主讯飞 → 备 DeepSeek → 三 Qwen，见 6.5）
数据源容灾	单源失效不影响整体	多源交叉验证 + 单源降权 + 备用源激活
图谱更新时效	T+1 更新	每日 05:00 前发布新版本（见 7.1）
ARQ 任务容错	失败自动重试	每 task 最多 2 次重试 + webhook/邮件告警
版本回溯	快照保留 90 天	PostgreSQL graph_versions 表 JSONB 字段存储 graph_v{date}.json
服务健康检查	5 服务健康状态	Docker Compose healthcheck + /health 端点

1.4.3 安全需求

安全维度	指标	实现方式（详见 11.2）
认证	JWT 双 Token（access 30min + refresh 7d）	RS256 非对称签名
授权	RBAC 三角色（admin/user/guest）	graph:read / resume:upload / match:run 权限粒度

安全维度	指标	实现方式 (详见 11.2)
限流	令牌桶 + IP 级别	普通 100 req/min, LLM 10 req/min
数据脱敏	日志自动替换	身份证/手机/邮箱正则脱敏
审计日志	保留 ≥ 180 天	4 分类: AUTH/GRAPH/DATA/ADMIN
CORS	白名单模式	生产仅允许前端域名
CSP	Content-Security-Policy	script-src / worker-src / img-src 限制
密码存储	bcrypt 加密	不可逆存储
简历数据隔离	自动脱敏 + 用户删除权	PIPL/GDPR 双合规

1.4.4 可扩展性需求

维度	当前规模	扩展预案
图谱节点	≥ 200 节点	Neo4j 读写分离 → Cluster
JD 数据量	单日 P0 ≥ 100 条, P1 ≥ 200 条	PostgreSQL 分区表 + Neo4j 批量入库
向量索引	IVF_SQ8 (低内存)	数据量 > 100 万切换 HNSW
用户并发	100 并发	FastAPI 异步 + Redis 缓存
LLM 调用	10 req/min	ARQ 队列削峰 + 多 provider fallback

1.4.5 可维护性需求

指标	目标值	验证方法
后端单元测试覆盖	≥ 60% (核心 ≥ 80%)	pytest-cov
前端单元测试覆盖	≥ 60% (核心 ≥ 80%)	Vitest + @testing-library/react
API 集成测试通过率	100%	FastAPI TestClient
E2E 测试通过率	100%	Playwright
ESLint	0 error, 无 any 穿透	CI 检查
TypeScript	strict 模式	tsconfig 编译
代码审查	算法/安全/业务逻辑 100% 人工审查	PR Review

1.4.6 兼容性需求

维度	目标	降级策略
浏览器	Chrome/Edge/Firefox 最新版	—
分辨率	1920 / 1280 / 1025 三档布局无错位	响应式断点 ≤640 / 641-1024 / ≥1025
WebGL	WebGL2 优先	降级至 2D D3.js 力导向图
移动端	基础可读 (非主要适配)	≥1025px 为主


1.4.7 数据质量需求

指标	目标值	评测方法
JD 解析准确率	≥ 90%	100 条标注黄金集 (技能达标口径=词面真值对齐, 见 §13.3)
简历提取准确率	≥ 90%	50 份标注黄金集
人岗匹配准确率	≥ 90%	100 对匹配黄金集

指标	目标值	评测方法
实体抽取 F1	≥ 0.88	200 条标注 JD（黄金集 100 条 JD 解析复用 + 100 条实体抽取专项标注，分批交付：M2 末 50 条、M3 中段 100 条、M3 末补齐 200 条）
SimHash 去重准确率	≥ 95%	人工抽检
Spearman 秩相关	≥ 0.85	100 对黄金集
Top-3 推荐准确率	≥ 90%	简历查询岗位任务
差距识别准确率	≥ 85%	50 份简历标注
学习路径合理性	≥ 80%	30 案例专家评审
新岗位定义采纳率	≥ 70%	人工审核统计
证据引用覆盖率	100%	自动校验
跨源置信度	≥ 0.6 入图谱	每日校验脚本

2. 总体技术架构

2.1 五层架构



2.2 技术栈选型

层级	技术选型	版本	选型理由
前端框架	Vite + React + TypeScript	React 19	3D图谱库 react-force-graph-3d 生态最优（作为可选模式）
可视化	ECharts（默认 2D）+ react-force-graph-3d（可选 3D）	—	2D 力导向图为主，3D 模式可选启用，大节点性能优于G6
样式	Tailwind CSS + shadcn/ui	v4	Utility-first + 可访问性组件库

层级	技术选型	版本	选型理由
状态管理	Zustand + TanStack Query	v5	轻量 + 服务端缓存策略完善
后端框架	Python FastAPI + Pydantic	0.115+	异步原生 + 自动OpenAPI文档
数据库	PostgreSQL 15 + SQLAlchemy 2.0	15	关系数据 + 异步驱动支持 + pgvector 向量检索 + JSONB 快照存储
图数据库	Neo4j 5.x + 全文索引 (cjkl)	5.x	Cypher 社区成熟 + 全文索引覆盖中文搜索; 图算法为自研 PageRank/Louvain/Leiden (igraph + leidenalg) , GDS 未引入
全文检索	Neo4j Full-Text Index + PostgreSQL tsvector	—	减少服务依赖, 中文搜索通过 Neo4j TEXT INDEX + cjkl 分词器覆盖
向量检索	pgvector (PostgreSQL 扩展)	0.7+	技能相似度检索 + IVFFLAT 索引 (低内存占用 + P95延迟 <300ms, 数据量 < 10 万场景最优)
缓存	Redis 7	7.x	缓存 + 限流 + 任务队列
大模型	OpenAI 兼容 API (讯飞星火 / Qwen / GPT / DeepSeek 等) + Anthropic Messages 协议 (如 z.ai Coding Plan /api/anthropic)	—	统一接口 + provider 可切换 (configs/llm_providers.yaml 按 protocol 路由, 非法协议构造期 fail-fast) , 兼容各类国产/开源模型
容器化	Docker + Docker Compose	24+	一键部署 5 服务 (api/postgres/redis/neo4j/worker)
任务调度	系统 cron + ARQ	—	ETL编排 + 异步任务队列
测试	PyTest + Vitest + Playwright	—	全栈测试覆盖

2.3 API 设计规范

统一响应格式：

```
{
  "code": 0,
  "msg": "success",
  "data": {},
  "trace_id": "a1b2c3d4-e5f6-7890-abcd-ef1234567890"
}
```

路由命名：

模块	前缀	说明
认证	/api/v1/auth	登录/注册/Token刷新/权限
图谱	/api/v1/graph	节点/关系CRUD、搜索、视图
简历	/api/v1/resume	上传、解析、编辑
匹配	/api/v1/match	匹配计算、差距分析、路径
演化	/api/v1/evolution	版本管理、Diff对比、趋势
管理	/api/v1/admin	用户管理 / 爬取管理 / 岗位审核 / 审计日志

2.4 API 接口契约总览

本节列出全部 REST 端点，作为前后端并行开发的契约基线。详细 Schema 定义存放于 `backend/openapi/` 目录，由 pactman 契约测试保证一致性。

2.4.1 认证模块 /api/v1/auth

方法	路径	认证	说明	请求关键字段	响应关键字段
POST	/login	公开	登录获取双 Token	username , password	access_token , refresh_token (refresh 另写 httpOnly Cookie)
POST	/refresh	refresh_token	刷新 access_token	refresh_token	access_token
POST	/logout	Bearer	登出, refresh_token 加入黑名单	—	—
GET	/me	Bearer	获取当前用户信息	—	id , username , role , permissions
POST	/register	公开	公开自注册 (固定 guest 角色, 认证端点纳入限流)	username , password	id , username , role

2.4.2 图谱模块 /api/v1/graph

方法	路径	认证	说明	请求关键字段	响应关键字段
GET	/position/{id}	公开	岗位节点详情 (匿名只读)	—	id , name , skills[] , core_duties
GET	/skill/{id}/evidence	公开	技能证据列表	—	[{evidence_id, source, url, confidence}]
GET	/skill/{id}/prerequisites	公开	先修技能链	—	[{skill_id, name, depth}]
GET	/skill/{id}/courses	公开	学习课程列表	—	[{course_id, title, platform, hours}]
GET	/view/{view_type}	公开	视图切换 (后端过滤)	view_type : panorama/techStack/positionCenter/positionPortrait (positionCenter 无页签, 供岗位画像下拉取数)	{nodes[] , edges[]}

方法	路径	认证	说明	请求关键字段	响应关键字段
GET	/search	公开	图谱搜索 (Neo4j 全文索引)	q, type, page, size	{total, items[]}
GET	/skill/similar	公开	相似技能检索 (pgvector)	skill_id, top_k	[[{skill_id, name, similarity}]]
GET	/skill/{id}/positions	公开	技能反向查询岗位 (哪些岗位要求该技能)	—	[[{position_id, name, necessity, weight, level}]]

2.4.3 简历模块 /api/v1/resume

方法	路径	认证	说明	请求关键字段	响应关键字段
POST	/parse	user+	上传简历触发解析 (异步)	file (multipart)	task_id (202 Accepted)
GET	/task/{task_id}	user+	查询解析任务状态	—	status, progress, result_ref
GET	/task/{task_id}/stream	user+	SSE 推送任务进度	—	event: progress/done/error
GET	/[{resume_id}]	user+	获取解析结果	—	{name, education, skills[], projects[]}
PUT	/[{resume_id}]	user+	编辑简历信息	fields	更新后数据
DELETE	/[{resume_id}]	user+	删除简历	—	—

2.4.4 匹配模块 /api/v1/match

方法	路径	认证	说明	请求关键字段	响应关键字段
POST	/recommend	user+	自动推荐 Top-N (异步)	resume_id, top_n (默认10)	task_id (202)
POST	/compare	user+	人岗比对 (单点同步)	resume_id, position_id	total_score, radar, gaps[]
GET	/task/{task_id}	user+	查询推荐任务状态	—	status, result[]
GET	/result/{match_id}	user+	获取匹配结果	—	total_score, must/nice/exp_score
GET	/result/{match_id}/gap	user+	获取差距分析	—	[[{skill, gap_type, priority}]]
GET	/result/{match_id}/path	user+	获取学习路径	—	[[{skill, prerequisites[], courses[]}]]
POST	/feedback	user+	提交匹配反馈	match_id, score (+/-)	—

2.4.5 演化模块 /api/v1/evolution

方法	路径	认证	说明	请求关键字段	响应关键字段
GET	/versions	guest+	获取图谱版本列表	page , size	[{version_id, created_at, summary}]
GET	/versions/{version_id}	guest+	获取版本详情	—	{nodes_count, edges_count, changes}
GET	/diff	guest+	版本对比	from , to	{added[], removed[], modified[]}
GET	/trends	guest+	技能趋势查询	skill , window (天)	[{date, freq, growth_rate}]
GET	/position/{id}/evolution	guest+	岗位演化历史	—	[{version, changes, timestamp}]

2.4.6 管理模块 /api/v1/admin


方法	路径	认证	说明	请求关键字段	响应关键字段
GET	/users	admin	用户列表	page , size	{total, items[]}
POST	/users	admin	创建用户	username , password , role	user_id
PUT	/users/{id}	admin	更新用户	role , status	—
DELETE	/users/{id}	admin	禁用用户	—	—
POST	/crawl/trigger	admin	触发爬取任务	platform , keyword	task_id
GET	/crawl/status	admin	爬取状态监控	—	[{platform, status, count}]
GET	/positions/pending	admin	待审核岗位列表	—	[{position_id, name, confidence}]
POST	/positions/{id}/review	admin	审核岗位（批准/驳回）	action , reason	—
GET	/evolution/pending	admin	待审核演化变更	—	[{change_id, type, skill, delta}]
PUT	/evolution/{id}/review	admin	审核演化变更	action , modified	—
GET	/audit/logs	admin	审计日志查询	category , start , end	{total, logs[]}

2.4.7 统一错误码

错误码	含义	触发场景	HTTP Status
4000	参数校验失败	Pydantic 校验不通过	422
4010	未认证	缺少/无效 Authorization 头	401
4011	Token 过期	access_token 超时，触发刷新	401
4030	无权限	RBAC 权限不足	403
4040	资源不存在	查询结果为空	404
4090	资源/状态冲突	重复创建、状态不可流转（如岗位状态不可审核）	409
4290	请求限流	超过令牌桶阈值	429
5000	内部错误	未分类异常	500
5001	Neo4j 查询失败	图数据库异常	500

错误码	含义	触发场景	HTTP Status
5002	pgvector 查询失败	向量检索异常	500
5003	LLM 超时	大模型调用超时	504

3. 项目时间节点



关键交付物（2026.09.05 初审提交）：

交付物	说明	负责
技术方案文档	本说明书 v1.0	文档
项目路演PPT	17页演示文稿	文档
演示视频	10分钟，6项核心功能	文档
完整源码	GitHub仓库	全员
Docker部署说明	DEPLOY.md	后端
测试数据集	100条标注JD黄金集	数据
评测报告	三项准确率≥90%	测试

4. 数据采集与预处理

4.1 多源数据采集

数据源矩阵 (3 国内 + 4 国际 + 3 社区 + 1 论文 + 3 课程 + O*NET, 共 13 源, 国内直连 + 国际走网络代理) :

分级	数据源	采集方式	频率	核心字段	代理走向	用途
A 级 (P0 主力)	BOSS直聘	Scrapy + Playwright (公开搜索页)	每日	岗位/薪资/技能/发布时间	国内直连	基准图谱 (国内主源)
A 级	智联招聘	Scrapy (列表页 + 详情页 SSR 正文)	每日	岗位/薪资/技能/发布时间 + 岗位职责/任职要求	国内直连	交叉验证 (国内)
C 级 (P2 实验)	LinkedIn (公开页)	Playwright (公开搜索页)	每日 ≤ 50 req	岗位名/公司名/技能标签 (不采完整JD文本)	代理池	国际岗位名称对照/跨源验证 (仅采公开元数据)
A 级	Monster	Scrapy + Playwright (公开页 + JSON 嵌入)	每日	岗位/薪资/技能/简历匹配	代理池	国际专业招聘 (IT/工程) 。[注意] 08.06 停采: DataDome 防护 (IP 信誉 + 浏览器真实性双重校验) 在容器环境实测不可绕过 (headless/CDP/指纹伪装/xdotool/人工滑块全被拦截), 已从自动调度移除, 代码保留待住宅代理/指纹浏览器后启用
B 级	Indeed	Scrapy + Playwright (公开搜索页)	每日	岗位/薪资/技能/企业评价	代理池	国际综合招聘 (覆盖广)
B 级	Glassdoor	Playwright (公开页 + 登录弹窗处理)	每日	岗位/薪资/企业评分/面试评价	代理池	薪资福利/雇主口碑维度
C 级 (P2 实验)	脉脉	Playwright (公开页面, 无登录)	夜间 23:00-06:00, ≤ 100 req/h	公开岗位名/公司名/技能标签	国内直连	职场社交维度 (仅公开可见元数据, S2+S3)
—	GitHub	PyGithub 官方 API	每日	Stars/Forks/Issues趋势	代理池	社区热度
—	StackOverflow	Stack Exchange 官方 API	每日	问题/标签热度	代理池	社区热度
—	arXiv	arXiv 官方 API	每日	论文/引用/分类	代理池	学术趋势
—	O*NET	O*NET 官方 API	一次性	标准职业分类	代理池	基线对照

分级	数据源	采集方式	频率	核心字段	代理走向	用途
—	中国大学MOOC	icourse163 公开页面	每周	课程/技能/讲师/评分	国内直连	学习路径（国内）
—	Coursera	Coursera Partner API	每周	课程/专项证书/合作院校	代理池	国际学习路径
—	edX	Open edX Catalog API	每周	课程/课程类型/开课时间	代理池	国际学习路径

数据源精简说明：相对原方案移除 Udacity/Khan Academy/Pluralsight 3 个课程平台（边际价值低，Coursera/edX 已覆盖国际课程维度）。M3 阶段若有余力可补充 Udacity 作为工业实战课程维度。

拉勾网移除：拉勾网破产重组、网页停止维护，招聘数据源已彻底移除，数据源总数 14 → 13（原 B 级国内补充源，无替代必要）。

智联详情正文采集：列表页仅含摘要（正文在详情页 SSR `__INITIAL_STATE__`），此前 description/requirements 留空、LLM 抽取仅依赖摘要（平均 117 字），职责描述抽取质量差。现列表页解析后对每条岗位发详情请解析正文（岗位职责/任职要求两小节）；详情页有验证码反爬，失败时降级为列表页摘要产出不丢数据。存量数据经 `scripts/backfill_jd_detail.py` 回填（8-15s 限速、幂等续跑）。实现见 `backend/data/crawlers/zhilian_detail.py`。

网络代理方案（D1b: Rule 模式）：开发环境配置 网络代理/V2Ray 系统代理（Rule 模式），国内平台（BOSS/智联/脉脉/中国大学MOOC）走 DIRECT 直连，国际平台（LinkedIn/Indeed/Monster/Glassdoor/GitHub/SO/arXiv/O*NET/Coursera/edX）走 Proxy 出口。爬虫代码不感知代理，由 网络代理 在系统层完成分流。网络代理 失效时仅国际平台降级，国内平台不受影响。

平台 A/B/C 分级管理：

- **A 级（P0 主力，稳定源）：**BOSS、智联、Monster —— 3 平台保底 P0 单日 ≥ 60 条。**[注意] Monster 停采**（DataDome 不可绕过，见 §4.3 平台表），保底由 BOSS/智联承担
- **B 级（P1 补充，次稳定）：**Indeed、Glassdoor —— 能跑就跑，失败当日停止。Glassdoor 已容器化落地（headless 采集，容器内实测 58 条入库）
- **C 级（P2 实验，风险源）：**脉脉、LinkedIn —— 黄金集不依赖

脉脉采集方式修正：放弃 H5 接口逆向 + mitmproxy 方案（在 Docker 环境中可行性低），改为 Playwright 采集未登录状态下可见的公开页面内容。仅作为 C 级实验源，不依赖其数据满足 P0 指标。

爬虫工程参数：

- **代理方案：**三梯队代理池，爬虫代码不感知代理，由 AdaptiveProxyMiddleware 自动切换
 - 第一梯队（代理池）：Rotating HTTP/HTTPS 代理池（可自建或使用公共代理服务），代理池连续 3 次失败后自动切换
 - 第二梯队（代理池）：PROXY_POOL 列表 + ProxyPoolMiddleware 随机轮换，代理失败自动剔除
 - 第三梯队（直连兜底）：仅对 Monster/Indeed 等部分对国内 IP 友好的国际站点生效；直连也失败则当日停止该源
- **User-Agent：**300+ 常用 UA 轮换（`scrapy-fake-useragent`）

- 请求间隔：国内平台 8-15s 随机；国际平台 10-20s 随机（保守限频）；LinkedIn 官方 API 按 quota 限流；GitHub/SO/arXiv 按 API 配额（GitHub 5000 req/h、Stack 10000 req/day、arXiv 1 req/3s）
- 增量调度：仅爬取发布时间 ≤ 7 天的新 JD，URL MD5 去重；跨平台相同岗位通过 (title, company, city) 三元组二次去重
- 历史数据回爬（M2 启动时一次性执行）：对 A 级核心平台（BOSS/智联/Monster），在采集首日回爬 90 天历史 JD 数据，用于在 M3 启动时为新岗位发现的 3 月 MA 频次分析提供基线数据。回爬限频与增量采集一致，不触发反爬机制。
- 失败处理：429/403 触发指数退避（30s $\rightarrow$ 60s $\rightarrow$ 120s $\rightarrow$ 300s），单日单源连续 3 次失败则该源当日停止采集并告警
- 国际平台降级策略：LinkedIn 优先官方 API，quota 超限时降级至公开职位页（C 级）；Indeed/Monster/Glassdoor 仅爬取无需登录的公开搜索页
- A/B/C 分级运行策略：A 级每日必跑（保底 P0）；B 级每日尝试，失败当日停止；C 级按需运行（脉脉夜间，LinkedIn 公开页仅 API 失效时）

爬虫开发交付节奏（单人多源约束）：M2 已完成 7 招聘源贯通（BOSS/智联/Monster/Indeed/Glassdoor/脉脉/LinkedIn 公开页）+ 清洗管线 + 6 非招聘源（arxiv/github/stackoverflow/icourse163/coursera/edx）；M3 时滞/通胀调优 + LLM 抽取管线；M4 课程平台对接学习路径 + 观察池接入。

本地限流中间件的配置：Scrapy 中间件栈含 UA 随机化、单 IP 限流与退避、URL 增量去重三层。完整实现见源码 `backend/data/crawlers/middlewares.py`，核心策略详见上文爬虫工程参数。

数据采集 P0/P1 指标体系：

指标	P0（必达）	P1（挑战）	题目硬性要求
单日 JD 总量	≥ 100 条/日	≥ 200 条/日	—
国内 JD	≥ 60 条/日	≥ 120 条/日	—
国际 JD	≥ 40 条/日	≥ 80 条/日	—
国际源占比	$\geq 30\%$	$\geq 30\%$	—
黄金集标注	M2 末 ≥ 50 条，M3 中段 ≥ 100 条	M2 末 ≥ 100 条	≥ 100 条
SimHash 去重准确率	$\geq 95\%$	$\geq 95\%$	—

4.2 数据清洗管线

管线顺序：`raw_JD` $\rightarrow$ 长度过滤 $\rightarrow$ 核心词检测 $\rightarrow$ 质量评分 $\rightarrow$ 去重 $\rightarrow$ 时效加权 $\rightarrow$ 结构化输出

质量过滤：长度 < 50 字丢弃、核心词检测、质量评分（字段完整度+文本长度+核心词+格式规范）， < 0.6 入人工复核。

去重：精确去重（URL+标题+公司名）、SimHash 64-bit 近似去重（汉明距 ≤ 3 ）、MinHash 兜底，抄袭 (≥ 0.85) 保留最新版本。

时效加权：`weight = 1.0 ( $\leq 30$ 天) / exp(-0.01x(days_ago-30)) ( $> 30$ 天)`，输出五标：`publish_time / crawl_time / decay_weight / source_platform / region`。

4.3 结构化输出

每条 JD 输出 JSON 格式，含 `job_title / company / salary_range / city / experience_required / education_required / responsibilities / requirements / benefits / publish_time / source_url / decay_weight` 等字段，详见源码 `backend/data/crawlers/schemas/jd_schema.py`。

4.4 ETL 调度

系统 cron + ARQ 编排每日管线：`crawl_jds  $\rightarrow$  clean_jds  $\rightarrow$  dedup  $\rightarrow$  validate_temporal  $\rightarrow$  detect_inflation  $\rightarrow$  structure  $\rightarrow$  load_to_db  $\rightarrow$  load_to_es`，异常阈值触发 webhook + 邮件告警。

数据更新频率：国内招聘平台每日 02:00/04:00，脉脉夜间 23:00-06:00 (≤ 100 req/h)，LinkedIn 每日 UTC 0:00，Indeed/Glassdoor 错峰 (**Monster 已停采**)，GitHub/SO 每日 UTC 0:00，arXiv 每日 UTC 3:00，课程平台每周日 UTC 2:00 全量同步，时效衰减每日凌晨 4:00 重算。

增量调度与重爬语义：

- 重爬不重抽：** `jd_raw` 以 `(source, source_id)` 唯一约束 upsert，JSONB 快照**合并写**（右覆盖左同键）——已有 `extraction` 键的 JD 重爬后保留旧抽取结果，不回退为“未抽取”。因此同一 JD 正文更新后**不会**自动触发重新抽取，图谱技能保持旧版。该取舍保证 ETL 幂等（不因重爬反复消耗 LLM 额度），代价是岗位要求变更的数据会滞后到人工重抽或图谱重建（`rebuild_graph.py`）。
- 入图失败可重试（P0-1）：** `batch_extract` 中**先入图后写 extraction 标记**——Neo4j 写入成功才在快照落 `extraction`，失败仅写 `extraction_error`（错误留痕审计），`extraction IS NULL` 游标下次批跑自动重试。避免了“先标记后入图”导致失败记录被游标永久跳过、数据静默丢失的问题。
- 低质 JD 不进抽取（P1-3）：** `needs_review`（质量评分 < 0.6 ）与正文过短记录在 `batch_extract` 选数阶段直接写 `skipped` 标记推进游标，不进入 LLM 抽取与入图，避免低质数据污染图谱。

4.5 多平台数据交叉验证

实体对齐策略：通过 `(normalized_title, normalized_company, city)` 三元组聚合不同平台同岗位 JD，公司名经 Sentence-BERT 编码 + 阈值 0.85 模糊匹配。

校验维度：

维度	校验逻辑	处置方式
技能一致性	必备技能集合跨平台命中	≥ 2 源 $\rightarrow$ <code>verified</code> ；单源 $\rightarrow$ <code>unverified</code> 进入人工审核
薪资异常	同岗位多平台薪资中位数差异 $> 50\%$	标记 <code>salary_outlier</code> ，人工复核
国内外对比	LinkedIn 与国内平台同岗位技能差异	输出 <code>skill_gap_intl</code> 报告供算法层调权
经验要求	同岗位经验要求跨平台不一致	取众数，标注分歧度

跨源置信度：融合数据源数量、跨源一致性与时效得分三项因子加权计算，单源数据直接标记为 `unverified`。区分 stable/emerging 岗位设置分级阈值——既有岗位入图谱 ≥ 0.6 ，新兴岗位下调至 ≥ 0.5 避免误杀新趋势。

数据准确性校验流程：每日 ETL 管线中 `cross_validate` 先于 `aggregate_positions` 执行——校验输出写回 `snapshot["cross_validation"]`，聚合阶段消费该置信度做**入门门控**：岗位组置信度 < 0.6 （新兴岗位 < 0.5 ）的 JD 不参与聚合，单源岗位（置信度上限 1/3）自动落入人工复核范围，结果经 lineage 页面与 `validation_report` 审计（含校验通过率、异常清单、门控拦截统计、人工复核队列）。

REQUIRES 边 weight 聚合策略：全量重算（幂等覆盖写）——`aggregate_positions` 每次 ETL 对全部已抽取 JD 全量重算聚合结果并覆盖写回 Neo4j。增量计算不可行：岗位级通胀剔除（岗位内通胀占比 $\geq 30\%$ 完全剔除）与平台级降权（源内通胀占比 $> 50\% \times 0.5$ ）依赖**全量 JD 的通胀占比统计**，仅聚合新增 JD 会破坏这些全局判定。全量重算在数据规模数千条时耗时可接受（幂等保证正确性优先），若数据量增长到全量耗时不可接受，需重构通胀统计为增量维护后再改增量。

must/nice 判定口径：

- 岗位 JD 数 ≥ 3 ：must 标注覆盖率 `must_count / jd_count` $> 1/2$ 判 must (weight=0.8)，否则 nice (weight=0.4)
- 岗位 JD 数 < 3 （样本不足）：回退 must 标注占比 `must_count / hit` $\geq 1/2$

修改原因：原口径（must 标注占比 $\geq 1/2$ ）下，LLM 对每条 JD 独立抽取的 must 技能跨 JD 重叠度低，真实库 85% 技能边被误判为 must（如“后端开发工程师”岗位出现 AGENT/MCU 芯片等边缘技能标 must），must/nice 失去区分度，匹配引擎必备技能匹配（\$9.4 must_score）与 CII 降级语义被稀释。修订后大样本岗位要求技能在过半数 JD 中标 must 才算必须，真实库 must 边由 2169 收敛至 680（样本不足岗位按原口径保留）。实现见 `backend/app/services/kg/aggregation.py::_is_must`。

4.6 课程质量评估

六维加权评分（平台权威性 0.25/用户评分 0.20/注册量与完成率 0.15/时效性 0.20/技能覆盖度 0.10/实战项目密度 0.10）， 阈值 ≥ 0.65 进入推荐池。时效性优先近 2 年课程， > 5 年降权 0.5。每月重跑评估管线，学习路径按质量分取 Top-3。

4.7 数据时滞专项处理

4.7.1 时滞来源分析

时滞类型	表现	覆盖情况
内容时滞	JD 日期新但技能沿用过时技术	× 原方案未覆盖，本节补充 SAI 检测
抄袭时滞	抄袭旧 JD 仅改日期	[注意] 原 SimHash 未识别"抄袭+改日期"，本节补充
发布/处理/展示时滞	发布时间、处理耗时、查询差异	√ 已有方案覆盖

4.7.2 内容时滞检测算法

核心思路：同岗位近期 JD 的技能分布应跟随技术趋势变化。若某条 JD 的技能集合与该岗位近 90 天 JD 集合的中位数技能分布显著偏离，且偏向"老技能"，则判定为内容时滞。

技能老化指数 (SAI)： $SAI(d) = \text{median}(\text{skill_age}) \text{ of } d / \text{median}(\text{skill_age}) \text{ of 岗位近 90 天 JD}$ ，其中 skill_age 基于 Skill.first_seen_at 计算。判定：SAI > 1.5 标记 content_stale (降权 $\times 0.5$)， > 2.0 标记 content_obsolete (归档不入聚合)。

僵尸 JD 检测：连续 N 个发布周期（默认 N=4，约 4 个月）内，某公司某岗位的 JD 技能集合 Jaccard 相似度 ≥ 0.95 （几乎不变），且 SAI > 1.5 $\rightarrow$ 标记 zombie_jd，仅保留最早版本，后续版本降权 $\times 0.3$ 。

4.7.3 抄袭时滞检测

在 SimHash 去重基础上增加时间维度对齐：若新 JD 与旧 JD 技能集合构成子集关系且发布时间间隔超过 90 天，标记为抄袭改日期，降权 $\times 0.4$ 不参与聚合。

4.7.4 时滞控制目标与衡量标准

环节	时滞类型	控制目标	衡量标准
数据采集	处理时滞	T+1 发布	每日 05:00 前完成 ETL
数据清洗	内容时滞	content_stale 占比 < 10%	每日 validation_report 统计
数据聚合	处理时滞	聚合耗时 < 30min	ARQ 日志
数据展示	展示时滞	图谱直查 Neo4j (无缓存)	API P95 < 500ms
内容质量	内容时滞	SAI > 2.0 的 JD 占比 < 5%	每周质量报告

4.7.5 异步处理优化

内容时滞检测为 ETL 管线中 validate_temporal 步骤（dedup 之后），SAI 依赖图谱层 Skill.first_seen_at 每日 04:30 增量更新。Skill 节点存储 first_jd_at / first_paper_at / first_trend_at 三个时间戳，聚合取最早非空值，JD 优先。僵尸 JD 检测每周末执行一次。

4.8 技能通胀专项处理

针对 JD 中技能要求"虚高"现象（如初级岗要求 10 年大模型经验），从经验、技能数量、技能深度、学历四个维度检测通胀。综合指数 `inflation_score`（四项加权，阈值 0.4/0.7 分三级），高通胀 JD 降权 $\times 0.4$ 、岗位级通胀（ $\geq 30\%$ ）排除该 JD 参与聚合、平台级通胀（ $>50\%$ ）触发源降权。M2 起实施，控制目标：通胀检测召回率 $\geq 80\%$ ，误报率 $\leq 15\%$ 。

5. 知识图谱构建

5.1 本体模型

实体类型（9 类，覆盖岗位/技能/证据/课程/原始数据/职业分类/认证/教育/工具）：

标签	属性	说明	数据来源
Position	id, name, level, industry, salary_range, occupation_code	岗位节点	JD 抽取 + 国家职业分类
Skill	id, name, normalized_name, category, description	技能节点	JD/课程/社区抽取
Evidence	id, source, url, publish_time, weight, source_type, company, platform, skill_necessity_map	证据节点（JD作为Evidence，含 source_type=jd）	JD/论文/GitHub/SO
Course	id, title, platform, url, hours, rating	课程节点	MOOC 平台
Occupation	id, code, name, category, definition	国家职业分类节点	国家职业分类大典（2022）/ O*NET
Certification	id, name, issuer, level, valid_years	证书节点	JD 抽取 + 行业认证库
Education	id, level, major, school_tier	教育要求节点	JD 抽取
Tool	id, name, category, vendor, version	工具/框架节点	JD/GitHub 抽取

国家职业分类数据接入：`Occupation` 节点以《中华人民共和国职业分类大典（2022 版）》为权威源（共 1639 个职业细类），同时交叉映射 *ONET 标准职业分类（SOC 代码）*，用于岗位归一化基线对照。数据通过人社部公开 API + ONET API 一次性导入，每季度校验更新。每个 `Position` 节点通过 `BELONGS_TO_OCCUPATION` 关联至 `Occupation` 节点，确保岗位命名规范与国家分类一致。

关系类型（9 类，覆盖要求/证据/先修/学习/演化/归属/相似/替代/职业映射）：

关系	语义	属性
(:Position)-[:REQUIRES]->(:Skill)	岗位要求技能	necessity(must/nice), weight, level
(:Skill)-[:EVIDENCED_BY]->(:Evidence)	技能由证据支撑	confidence, source_type
(:Skill)-[:PREREQUISITE_OF]->(:Skill)	技能先修关系	—
(:Skill)-[:LEARNABLE_VIA]->(:Course)	技能可学习	platform
(:Position)-[:EVOLVED_FROM]->(:Position)	岗位演化自	version, change_type
(:Skill)-[:BELONGS_TO]->(:Skill)	父子技能（如 Spring Boot → Java）	—
(:Skill)-[:SIMILAR_TO]->(:Skill)	相似技能	similarity(0.0-1.0)
(:Skill)-[:ALTERNATIVE_OF]->(:Skill)	可替代技能（如 React ↔ Vue）	—
(:Position)-[:BELONGS_TO_OCCUPATION]->(:Occupation)	岗位归属国家职业分类	match_confidence

Neo4j 约束与索引（8 类实体共 10 个 UNIQUE 约束，其中 Position 与 Skill 各含 id+name 两个约束 + 7 个索引）：

8 类实体节点均有 UNIQUE 约束（id/name/code），并建有 skill.category、skill.normalized_name、position.level、evidence.source_type、occupation.category 等 5 个加速索引，以及 Skill/Position 各 1 个全文索引（cjk 分词器覆盖中文搜索）。完整 DDL 见源码 backend/app/services/kg/schema.cypher。

5.2 实体与关系抽取

实体抽取管线（LLM Few-Shot + 词典后过滤）：LLM Few-Shot 抽取（5 条示例 + JSON Schema 强校验）→ 词典后过滤（SKILL_ALIAS 词典扫描 JD，过滤 LLM 越界技能）→ 中文后缀清洗（去除"系统/框架/技术/工程师"等 30+ 后缀）。

关系抽取：

- 依存句法分析（HanLP/LTP）+ Prompt 模板
- 识别三类关系：岗位-技能、技能-先修、技能-课程
- 每条关系必须挂载 ≥ 1 个 Evidence 节点（来源URL + 发布时间 + 置信度）

岗位归一化（normalize_position_name）：抽取出的原始岗位名经多步归一化为标准岗位族，作为 Position 节点聚合与匹配的唯一口径。步骤：

1. 英文岗位名翻译为中文（_EN_POSITION_MAP，容忍逗号/连字符；含中文的混合标题不翻译，防内嵌缩写被劫持）
2. 循环去后缀（工程师/开发/分析师等）至核心词，按 _POSITION_KEYWORDS 关键词族映射为标准岗位名；细分族（数据分析/分析师/嵌入式等）在前优先命中
3. 分析师资细分（_ANALYST_SUB_FAMILIES）：仅对"分析师"结尾岗位生效，量化/财务/信贷等细分优先，否则兜底"分析师"
4. 停用词拦截（_POSITION_STOPWORDS）：碎片/非技术岗/含地点公司残留返回空串，不入图
5. **失真兜底族技能路由**：软件开发工程师/科学家/架构师/研究员/顾问/硬件工程师/解决方案工程师/专家/算法工程师等标题级兜底词不再作为聚合目的地——命中后按 JD 已抽取技能（skills 参数）经 _POSITION_SKILL_ROUTING 路由到细分族（视觉/自动驾驶/大模型/语音/机器人 → 通用算法 → 大数据/数据分析/前端/后端/DevOps/网安/测试/嵌入式/数据库 → 语言族兜底）；无技能或未命中路由返回空串不入图，防止方向各异的 JD 混聚单节点导致技能集合失真
6. 技能词不入图：归一化结果命中技能白名单时视为"技能被抽成岗位"，返回空串

实现见 backend/app/services/extraction/dictionary.py，调用点需传 skills 保持口径一致（batch_extract 快照、discovery_daily 聚合、cross_validate 写回、kg_service import_jd 二次归一化、aggregation 聚合）。回归校验脚本：backend/scripts/reposition_generic_positions.py。

5.3 技能归一化

Sentence-BERT 编码 → 层次聚类（阈值 0.25）→ 人工词典兜底，输出 standard_id + confidence。结果回写至 Skill.normalized_name，相似度 ≥ 0.85 时自动建立 SIMILAR_TO 关系。

量化指标（实现见 guard_cluster_distribution）：

指标	定义	达标线
归一化写回覆盖率	图谱全量 Skill 均有 normalized_name（含自指，即自身已是标准形式）	100%
映射率（改写率）	standard ≠ 原名 的技能占比；越界判定为聚类失效（<5%）或链式漂移（>90%），拒绝写回	[5%, 90%]
最大语义簇	任一标准名下成员数；超限疑似漂移簇污染，拒绝写回	≤ max(50, 技能总数 × 2%)

全量验证：6593 技能映射率 57.2%（3769 映射）、最大簇 AI=106（上限 132），全部达标。

6. 大模型应用策略

6.1 管线架构



6.2 Prompt 工程

分层设计: System Prompt (角色定义) → Task Prompt (提取要求) → Few-Shot Examples (5 条) → Input。详见源码 `backend/app/services/prompts/`。

参数配置:

- `temperature = 0.1` (低随机性保证稳定)
- `max_tokens = 2048`
- `top_p = 0.9`

6.3 幻觉防控三道防线

防线	方法	触发条件	处理方式
第一道	JSON Schema强校验	字段缺失/类型错误/枚举越界	自动重试1次, 失败降级规则提取
第二道	跨源交叉验证	实体仅1个数据源出现	标记 <code>unverified</code> , 不入生产图谱
第三道	规则白名单后过滤	实体不在500+标准技能白名单中	对齐O*NET/Wikidata, 未对齐走审核

6.4 RAG 检索增强

检索策略:

- 检索源: 图谱中已验证的岗位定义 + 技能描述 + 历史诊断报告
- 检索方法: Neo4j 全文索引 (关键词 top-10) + pgvector 向量检索 (语义 top-10), 合并去重
- 上下文窗口: 截取前3000 tokens, 超出丢弃

生成约束: 仅基于证据生成回答, 证据不足时明确说明; 每条断言附加 `evidence_id`, 虚构引用拦截并重新生成。

6.5 LLM API 降级策略

多 Provider 配置:

主备三个 provider 均通过 OpenAI 兼容 API 接入, 配置存放于 `configs/llm_providers.yaml`, 下表为当前生效的默认组合 (可被管理员后续调整):

优先级 (默认)	Provider	模型	适用场景	备注
主	DeepSeek	deepseek-v4-flash	全场景 (抽取/匹配/诊断)	支持 function calling
备	讯飞星火	v4.0	全场景	支持 function calling
三	Qwen	qwen-plus	全场景	支持 function calling

同步重试链策略 (按路由类型区分):

路由类型	重试策略	超时上限	失败处理
同步路由（图谱查询、诊断报告等）	主 API 超时 10s → 立即返回 504 错误（错误码 5003，§2.4.7），前端提示「LLM 暂时不可用，点击重试」	10s	不重试，避免同步阻塞
异步任务（ARQ：简历解析、批量抽取、演化计算）	主超时 30s → 备 30s → 三 30s → 入延迟队列等待恢复	90s	全部失败后任务标记 failed，等待人工介入或定时重试

触发条件：

场景	触发条件	降级动作	恢复条件
主 API 超时（>10s 同步 / >30s 异步）	单次超时	同步路由：返回 504（错误码 5003）；异步任务：切备 provider	主 API 健康检查连续 3 次 200
主 API 限流（429）	单次 429	异步任务：指数退避（30s→60s→120s）后切备 provider	限流解除后自动恢复主
主 API 不可用（5xx）	连续 3 次 5xx	全部切备 provider + 告警	主 API 健康检查通过 5min
全链路不可用	主+备+三均失败	异步任务标记 failed，规则兜底（关键词匹配+模板报告，标 low_confidence）	人工介入后重跑

实现要点：

- `LLMProviderChain` 类管理 provider 轮换逻辑，读取 `configs/llm_providers.yaml`
- 同步路由调用 `llm.call_sync(prompt)` → 单次尝试，超时即抛 `LLMTimeoutError`
- 异步任务调用 `llm.call_with_fallback(prompt)` → 按优先级依次尝试，全部失败后入延迟队列
- provider 健康检查：每 5min 调用 `/models` 端点验证可用性，结果写入 Redis
- 主 API 恢复后，由 `failed` 状态的异步任务自动重新入队重跑（不污染图谱质量）

批量抽取优化设计（原型已验证）：

`batch_extract` 当前逐条调用 LLM（855 条 JD 抽取 ≈ 24min/160 条），拟优化为「N 条/批组批 → 一次 LLM 调用 → 拆条落库；整批失败/结果错位时降级逐条」。原型实测（oc-deepseek）：单条 ×3 耗时 7.29s（2.43s/条），单轮塞 3 条耗时 2.59s（0.86s/条），提速约 2.8 倍（瓶颈为每请求固定开销——网络往返 + 首 token 延迟，批量将其从 N 次摊成 1 次）。

最终参数：

参数	最终值	说明
批量独立超时	<code>batch_timeout</code> 60~90s/批（单条 <code>ASYNC_TIMEOUT_SECONDS=30</code> 不变）	批量 N 条输出 token 线性放大，按批超时
<code>_BATCH_REQUEST_INTERVAL</code>	批间限流缓冲	频率从 N 降到 N/batch_size
<code>job_timeout</code>	1800s	批量后总耗时下降，余量充足
批大小	按批内文本总长度动态封顶（ <code>max_batch_chars</code> ，如 8000 字符）	JD 正文长短不一，按文本长度封顶保证每批成本稳定

编排语义（原型行为基线）：

- 按 `batch_size` / 文本长度封顶组批，每批一次 LLM 调用
- 整批失败（LLM 异常 / 超时）→ 仅该批降级为逐条抽取，不拖垮已成功批次
- 错位防护：批量返回条数 ≠ 输入条数 → 判定张冠李戴风险，该批降级逐条（原型测试 `test_wrong_count_falls_back_to_single`）
- 单条接口 `JDExtractor.extract` 保留不变，作为降级路径与其他调用方（resume 解析 / evaluate / backfill 脚本）使用，批量为新增编排层，路径隔离

7. 动态演化与新岗位发现

7.1 时间窗口演化算法

增长率计算：采用**Z-score 统计 + 环比 (MoM) 辅助**双信号。Z-score 只需 ≥2 个历史窗口即可计算，适配项目 90 天回爬数据周期。

Z-score（标准分）为主要判定信号， $z = (f(t) - \mu) / \sigma$ ，其中 f(t) 为当前窗口取值，μ/σ 为历史窗口均值/标准差，口径以快照序列为单位统一：全部窗口均有占比分母时 f(t) 为**归一化占比**（该技能 REQUIRES 频次 / 当期快照 REQUIRES 总边数，分子分母同边集，抗采集总量波动——爬虫宕机全技能频次齐跌时占比不变，不批量误判 declining）；任一窗口缺分母（旧快照无 relation 标注）则整条序列退回原始计数。判定阈值： $z > 2.0 \rightarrow \text{emerging}$ ， $z > 1.5 \rightarrow \text{rising}$ ， $z < -1.5 \rightarrow \text{declining}$ 。环比（MoM）辅助观察短期方向（原始计数口径）。频次 < 10 的技能受小基数保护不参与严格门控（严格门控要求 `jd_freq_ma3 ≥ 10`）；命中 data_warning（证据量萎缩 <50%/膨胀 >200%）的快照整期不作为判定输入；快照窗口不足无法计算 Z-score 时改用 Wilson score 冷启动兜底（见 §7.2.3/§7.2.4）。

版本管理：

- 每次演化生成 `graph_v{date}.json` 全量快照（APOC），存入 PostgreSQL `graph_versions.snapshot_json` JSONB 字段
- `GraphVersion` 节点记录：`version_id`, `created_at`, `change_summary`, `triggered_by`
- Diff 对比：set 差集计算新增/删除/变化节点

T+1 图谱更新承诺：岗位图谱遵循 T+1 更新节奏——每日凌晨 4:00 ETL 完成后（爬虫→清洗→去重→结构化→图谱增量同步），于 5:00 前自动发布新版本。用户在每日 5:00 后查询到的图谱数据已包含前一日全部新增/变更 JD 的影响。版本快照保留 90 天，支持任意历史版本回溯对比。

图算法应用：

算法	用途	实现
PageRank	技能重要性排序	<code>gds.pageRank.stream()</code> → Top-20 关键技能
Louvain	技能簇识别	<code>gds.louvain.stream()</code> → 技术栈视图支撑
Leiden (技能共现)	技能簇层级索引	<code>igraph+leidenalg</code> ，共现边按 <code>must/nice</code> 加权（ <code>sync_communities</code> ）
Leiden (岗位投影)	岗位职能域	岗位-岗位共享技能加权投影（ <code>must</code> 共享 1.0/ <code>nice</code> 0.3、共享 <2 过滤）， <code>resolution=1.55</code> ，单点簇合并通用桶，回填 <code>Position.domain_id/domain_name</code> （ <code>sync_position_domains</code> ，08-22）。动机：技能社区对岗位域不可用—— <code>min_weight</code> 过滤后仅 7% 技能有社区、金融类技能边全 <code>nice</code> 整域滤出图外；消费方为能力图谱域聚合下钻
最短路径	学习路径先修排序	<code>shortestPath((:Skill)-[*..6]-(:Skill))</code>

7.1.1 既有岗位动态更新示例——以 Java 开发工程师为例

时间窗口	技能变化	类型	证据	置信度
2026-Q2	Spring AI 框架	新增	BOSS+智联 201 条JD，出现频次增长 62%；GitHub Spring AI Stars 突破 35k	0.89
2026-Q2	GraalVM 原生编译	新增	跨 3 源（JD + GitHub + SO），growth_rate = 78%	0.82
2025-Q4	LLM API 调用能力	新增	102 条 JD 新增 "AI 集成/大模型调用" 关键词	0.76
2024-Q2	JSP/Servlet	衰退	连续 3 窗口 decline_rate > 50%，仅出现在 ≤ 5% JD 中	0.93
2025-Q1	Docker/K8s	权重提升	跨 4 源一致 necessity → must	0.91

7.2 新岗位发现

7.2.1 岗位分类标准与状态机

岗位全生命周期采用七状态机模型（发现状态机六态 + active 图谱常态态），状态属性持久化至 Neo4j 节点：

状态	含义	进入条件	流转方向	是否公开
active	活跃态（图谱常态态）	新 JD 导入岗位默认态（import_jd）；存量岗位一次性迁移	非发现状态机成员，审核/发现链路命中后按需进入候选流	是
candidate	候选态	趋势监测命中规则门控	→ emerging / → rejected	否
emerging	新兴态	跨 ≥2 独立源验证 + 置信度 ≥ 0.6	→ stable / → declining	是
stable	稳定态	jd_count ≥ 5 + source_diversity ≥ 2 + 最近 2 窗口不对称萎缩幅度 < 25%（只惩罚萎缩、增长不惩罚） + skill_novelty < 0.2	→ declining	是
declining	衰退态	连续 3 窗口频次下降 > 40%（三窗口下降率均值）	→ archived / → stable	是
archived	归档态	人工审核确认衰退（仅曾上线的岗位进入此态）	终态，可回溯	否
rejected	驳回态	admin 审核驳回 candidate	终态，不入图谱，仅保留审核日志	否

转换条件：窗口为 30 天滑动窗口。自动转换条件见上表状态机，人工参与仅涉及 candidate→emerging/rejected（admin 审核）和 declining→archived（admin 确认衰退）。

stable 条件口径说明：

- jd_count：jd_raw 中该岗位真实 JD 数（auto_transition 任务按岗位名统计）
- source_diversity：JD 独立源计数（§7.2.2 特征定义，原表格 platform_count 的实现口径）
- skill_novelty：岗位 REQUIRES 技能平均图谱年龄归一化 $1 - \min(\text{avg_age_days} / \text{参考周期}, 1)$ ，参考周期自适应图谱生命周期（最早技能首见时间至今——冷启动阶段固定 365 天会让全部技能 novelty≈0.99，任何岗位无法 stable）；数据源 Neo4j Skill.first_seen
- 阈值 0.2：自适应参考周期下技能需出现 $\geq 0.8 \times \text{生命周期}$ 才判定成熟

自动化与人工审核矩阵：

转换	自动化	人工	说明
→ candidate	√ 自动	—	每日定时任务，规则门控
candidate → emerging	—	√ admin 审核	管理后台每周审核队列
candidate → rejected	—	√ admin 审核	同上
emerging → stable	√ 自动	—	条件满足即自动迁移，记录日志
emerging → declining	√ 自动	—	条件满足即自动迁移

转换	自动化	人工	说明
stable → declining	√ 自动	—	条件满足即自动迁移
declining → archived	—	√ admin 确认	需填写审核理由
declining → stable	√ 自动	—	条件满足即自动回迁

前端演化看板按状态着色：活跃-蓝灰 / 候选-灰 / 新兴-绿闪烁 / 稳定-蓝 / 衰退-橙 / 归档-红 / 驳回-灰透明。

7.2.2 特征提取规则

从多源数据提取 4 项核心特征 + 2 项辅助加分特征作为判定输入：

核心特征（4 项，Z-score 门控主判定信号，仅 JD 源驱动）：

特征名	提取方法	说明
jd_freq_ma3	PostgreSQL 聚合 + 3 月移动平均	JD 频次基线
z_score	$(f(t) - \mu) / \sigma$ ， μ/σ 为历史 30 天 JD 窗口统计	JD 频次异常度，Z-score 主判定信号
source_diversity	JD 独立源计数（BOSS/智联/脉脉等）	JD 跨源验证强度
cross_source_consistency	三源 JD 语义相似度均值	JD 跨源一致性

辅助加分特征（2 项，参与 candidate→emerging 置信度加成，不作为 candidate 触发门控）：

特征名	提取方法	说明	上线阶段
arxiv_paper_count	arXiv API 周论文数 + 引用增长率， $\delta > 2\sigma$ 为异常	学术关注度信号，验证技术早期学术热点	M4
github_star_velocity	GitHub API Star 增速标准分， $\delta > 2\sigma$ 为异常	社区活跃度信号，验证技术工业界采纳	M4

分层源策略：

- **JD 源（招聘平台）**：驱动 candidate 触发。JD z_score 命中即进 candidate 池，遵循 6.3 「≥2 JD 源入图谱」门控。
- **学术/社区源（arXiv/GitHub/SO）**：进入「技术热点观察池」，admin 周报可见，**不独立触发 candidate**。仅在 candidate→emerging 阶段作为置信度加分项。
- **设计依据**：arXiv/GitHub 是技术热度信号，不是岗位信号。技术热点 ≠ 新职业（如「Spring AI」技术热点与「Spring AI 工程师」新岗位是两个概念）。让技术热点独立触发 candidate 会导致大量假阳性涌入审核队列，admin 负担过重。
- **观察池升级路径**：观察池中的技术热点若在某周开始出现于 JD（即使频次低），将自动提升为 candidate 候选，进入正式判定流程。

辅助加分机制：两项辅助特征不参与 candidate 触发的硬性判定（避免 M3 未集成时门控失效），但在 candidate→emerging 阶段二置信度计算中作为加分项——当 arxiv_paper_count 或 github_star_velocity 任一异常（ $\delta > 2\sigma$ ）时，candidate 的置信度 +0.1；两者均异常时 +0.15（封顶 1.0）。这样学术热点与社区活跃可助推候选岗位进入 emerging，但无法单独促成候选（仍需 JD 频次 + 跨源验证作为基线）。

社区/学术口径对齐：arXiv 学科分类码（cs.LG 等）与 GitHub/SO 标签天然为英文 token，而 JD 侧抽取技能名以中文为主（如「机器学习」）。二者不经映射无法在 (skill, source) 周频次中相交，曾导致 arxiv 辅助信号长期全 false、github 命中率极低——信号「检测到但用不上」。现于观察池聚合层（watch_pool.extract_skills）对社区/学术 token 统一执行「社区别名映射 → normalize_skill → is_noise_skill 去噪 → 去重」，将 cs.LG/machine-learning 等落到与 JD 一致的技能名后再参与 2σ 判定与置信度加分；arxiv 论文 language 属书写语言、非技术技能，

不再纳入。映射目标须避开 `SKILL_STOPWORDS` 停用泛词（如「人工智能」），否则映射结果会被判噪丢弃。此改动仅提升社区信号与 JD 技能口径的对齐率，**不改变「学术/社区源不独立触发 candidate」的分层定位**。

放弃原 12 维特征的原因：①算法岗 1 人 7 周内无法完成 BERTopic 连贯性、媒介落差指数 MLI 等外部数据源集成（各需 2-3 天）；②80-120 正样本 / 12 维特征，样本/特征比 7:1，低于推荐的 10:1-15:1，逻辑回归严重过拟合；③特征分阶段上线表中 `media_lag / industry_adoption` M4 才上线，但阶段一硬阈值依赖这两项，M3 阶段一门控失效。降维为 4 项核心 + 2 项辅助后，保留学术/社区信号参与判定，同时避免硬性门控依赖。

7.2.3 判定流程

单阶段判定：Z-score 统计门控 + RAG 接地

阶段一（Z-score 统计门控，4 项核心特征，仅 JD 源驱动）：

```
IF z_score > 2.0 AND source_diversity ≥ 2 AND jd_freq_ma3 ≥ 10 → candidate
ELIF z_score > 1.5 AND source_diversity ≥ 2 → candidate（保守观察）
ELSE → 继续监测
```

冷启动处理（Wilson score 兜底）：

冷启动不再以历史窗口天数判定——z_score 可计算（快照窗口 ≥2 个）时
直接使用 Z-score 门控，与历史窗口天数无关（
`history_days < 60` 一律禁用 Z-score 走 Wilson，但 Wilson 下界在 JD 占比下
极低（实测 0.005-0.185）永不达 0.3 阈值，candidate 发现功能整体失效）。
仅当 z_score 为 None（快照窗口不足，无法计算 Z-score）才走冷启动 Wilson：
`wilson_lower > 0.2 AND source_diversity ≥ 2 → candidate`（保守判定）
（阈值 0.3→0.2，源数 3→2；样本口径改为“首现后窗口出现
率”后，首现即出现 1 个窗口的岗位 Wilson 下界 ≈0.206，0.3 阈值下需等第 2 个
窗口才被检测；0.2 允许首窗口确认后即入池。单源/双源新出现岗位被 3 源门槛
永久拦截，与成熟岗位排除机制配合后调降至 2 源安全。）
详见 §7.2.4 置信度计算公式。

阶段二（RAG 接地 + 种子列表匹配，仅对 candidate 触发）：

```
candidate → RAG 检索权威岗位库（人社部职业分类 + LinkedIn Emerging Jobs + O*NET）
IF 匹配权威定义 → 生成岗位定义草案 → admin 审核 → emerging/rejected
ELIF 匹配种子列表（预置 12 个新兴岗位种子） → 生成岗位定义草案 → admin 审核
ELSE → 标记 unverified，继续监测
```

阶段启用节奏：

- **M3 阶段：**阶段一信号检测全程运行，candidate 候选池开始积累。阶段二 RAG 接地 + admin 审核暂不开放自动 emerging 判定（影子模式），仅人工手动触发用于演示样本生成。
- **M4 阶段：**阶段二 emerging 自动判定开放。candidate→emerging 流程预计 2-3 天/岗位（RAG 检索 + LLM 生成定义 1 天 + admin 审核 1-2 天），8/28 前预计可产出 1-3 个 emerging。
- **17.3 测试数据交付策略：**采用双案例——① 预置种子引导案例（M3 期间人工触发全流程产出）；② 真实自动发现案例（M4 自动判定产出）。若真实案例因数据窗口或时点未达 emerging，则交付 candidate 状态 + 声明「已识别但需更多数据确认」，不掩饰。

种子列表：预置 12 个新兴岗位种子（如 AI Agent 工程师、RAG 工程师、大模型应用开发、数据工程师、MLOps 工程师等），参考 talent-graph-system 的 `EMERGING_SEEDS` 模式。种子列表存储在 `configs/emerging_seeds.yaml`，支持运营扩展。

RAG 接地：候选岗位通过 RAG 检索权威岗位库（人社部《国家职业分类大典》、LinkedIn Emerging Jobs 年度报告、O*NET），匹配已确认的新兴岗位定义。检索方法：Neo4j 全文索引（关键词 top-10）+ pgvector 向量检索（语义 top-10），合并去重。匹配后 LLM 聚合技能上下文生成岗位定义草案，参考 talent-graph-system 的 RAG 接地方案。

稳定化/衰退：emerging → stable: 最近 2 窗口不对称萎缩幅度 < 25%（增长不惩罚）AND source_diversity ≥ 2（+ jd_count ≥ 5 + skill_novelty < 0.2, 见 §7.2.1 表格）stable → declining: 连续 3 个 30 天窗口频次下降 > 40%（decline_rate = (prev_freq - curr_freq) / prev_freq）declining → stable: 频次回升（z_score > 0 连续 2 窗口）

放弃逻辑回归训练数据构造：原方案的"200 正样本 + 1000 负样本 + 5 折交叉验证 + 正样本双层过滤"整套流程不再需要，节省 ~10 人天。Z-score 无需标注数据，RAG 接地依赖权威文件而非训练数据。

7.2.4 置信度计算公式

状态机中 candidate → emerging 要求"置信度 ≥ 0.6"，本节给出置信度的显式计算公式，消除阈值表无公式可依的歧义。

综合置信度采用三维加权（权重和 = 1.0）+ 学术/社区加分，三个因子均归一化至 [0, 1]：

```
# 基础置信度（三维加权）
confidence = w_count × norm(jd_count) + w_source × source_diversity + w_growth × norm(growth_rate)

# 默认权重（可由 configs/discovery_weights.json 覆盖）
w_count, w_source, w_growth = 0.4, 0.3, 0.3

# 归一化函数
norm(jd_count)      = min(jd_count / 10, 1.0)      # 10 条 JD 即满分
norm(growth_rate)   = min(growth_rate / 0.5, 1.0)   # 50% 增长率即满分
source_diversity     = min(source_count / 4, 1.0)    # 4 个独立源即满分

# 学术关注度 / 社区活跃度加分（M4 上线后启用，M3 仅用基础置信度）
if arxiv_anomaly and github_anomaly:
    confidence += 0.15 # 学术 + 社区双异常，强信号
elif arxiv_anomaly or github_anomaly:
    confidence += 0.10 # 单一异常，中等信号
confidence = min(confidence, 1.0) # 封顶 1.0
```

冷启动兜底（Wilson score 区间）：当 z_score 不可计算（快照窗口不足，无法获得 Z-score 基线）时，上述频次/增长率因子不可靠，改用 Wilson score 二项区间下界作为保守估计（与 §7.2.3 冷启动触发条件一致，不按历史窗口天数判定）：

```
from math import sqrt

def wilson_lower(successes, total, z=1.96):
    """Wilson score 95% 置信区间下界 (z=1.96 对应 95%) """
    if total == 0:
        return 0.0
    p = successes / total
    denominator = 1 + z * z / total
    center = p + z * z / (2 * total)
    spread = z * sqrt(p * (1 - p) / total + z * z / (4 * total * total))
    return max(0.0, (center - spread) / denominator)

# 冷启动时: successes = 出现该技能的 JD 数, total = 总 JD 数
# wilson_lower > 0.2 → 可进入 candidate 池 (保守判定)
```

状态机阈值映射：

状态转换	置信度条件	说明
→ candidate	规则门控命中（不依赖置信度）	阶段一硬阈值
candidate → emerging	<code>confidence ≥ 0.6</code> AND <code>source_diversity ≥ 2</code>	人工审核 + 置信度双条件
emerging → stable	<code>jd_count ≥ 5</code> + 最近 2 窗口不对称萎缩幅度 < 25%（增长不惩罚） + <code>source_diversity ≥ 2</code> + <code>skill_novelty < 0.2</code> （08-15 全量对齐，不再用 <code>confidence ≥ 0.8</code> ——小基数岗位其他维度满分也能过 0.8，提前稳定）	自动迁移
冷启动兜底	<code>wilson_lower > 0.2</code> → candidate（保守判定）	<code>z_score</code> 不可算（快照窗口不足）时启用，与历史天数无关

设计依据：本项目采用 3 因子（频次/源多样性/增长率），与 12 维特征中最重要的 3 项对齐。

7.2.5 趋势监测与岗位定义生成

条件监测矩阵：

信号源	指标	阈值
JD频率	3月移动平均环比增长率	> 50%
arXiv论文	周论文数 + 引用增长率	超过历史均值2σ
GitHub	Star增速	$\delta > 2\sigma$

产业化拐点判断：采用媒介落差指数（MLI）综合论文、课程、社区讨论与招聘平台四维信号， $MLI > 0.6$ 判定为 Ready-to-industrialize，避免学术热点但工业界未跟进的误判。

岗位定义生成：RAG 双角色设计——角色一检索图谱检测重复，角色二聚合技能上下文辅助 LLM 生成岗位定义。

7.2.6 评估指标

指标	目标值	评测方法
emerging 判定 Z-score 准确率	≥ 80%	对照行业报告人工抽检
新兴岗位召回率	≥ 80%	对照行业报告
误报率	≤ 15%	季度复盘抽检

指标	目标值	评测方法
首次出现到 emerging 耗时	≤ 60 天	系统日志
岗位定义采纳率	≥ 70%	审核队列通过率
evidence_refs 覆盖率	100%	自动校验

8. 简历解析

8.1 文件解析

文件类型	解析库	说明
PDF（文本型）	pypdf + pdfplumber	优先文本提取，处理段落与表格
PDF（扫描件）	PaddleOCR（ch_PP-OCRv4）+ 预处理	图像增强（自适应阈值 + 去噪）→ OCR → 后处理（拼写校正）
PDF（双栏版式）	pdfplumber + 布局分析	page.search() + 列边界检测，按阅读顺序重组文本
PDF（表格简历）	pdfplumber + Camelot	优先检测表格区域，提取后与正文段落合并
Word	python-docx	直接提取段落、表格与样式
图片	PaddleOCR	OCR识别后输入LLM抽取

复杂版式处理流程：

文件上传 → 类型检测

- └ 文本PDF → pypdf 提取 → 若空白则 pdfplumber → 若仍空白则 OCR
- └ 扫描件PDF → pdf2image 转图片 → 自适应阈值 + 去噪 → PaddleOCR → 后处理
- └ Word → python-docx 提取段落+表格 → 合并为纯文本
- └ 图片 → PaddleOCR 直接识别

→ 文本串联 → LLM 结构化抽取

双栏简历处理：通过 pdfplumber 检测中线空白带判定双栏布局，按 y 坐标交替拼接左右栏文本。表格简历使用 Camelot 提取。详见源码 `backend/app/services/resume/reflow.py`。

8.2 PII 脱敏预处理

简历文本在送入 LLM 抽取前**必须先经 PII 脱敏**，避免敏感信息泄露给外部 LLM API（PIPL/GDPR 合规要求）。

脱敏规则（正则替换，脱敏后的占位符保留语义上下文供 LLM 抽取）：

PII 类型	正则模式	替换为	说明
手机号	1[3-9]\d{9}	[PHONE]	11 位中国大陆手机号
身份证号	`[1-9]\d{5}(18	19	20)\d{2}(0[1-9] 1[0-2])(0[1-9] [12]\d 3[01])\d{3}[\dXx]`
邮箱	[\w\.-]+@[\w\.-]+\. \w+	[EMAIL]	标准邮箱格式
中文姓名	姓氏词典（百家姓前 100）+ 名字长度 1-2 字	[NAME]	基于姓氏词典启发式匹配，避免误替换技术名词

脱敏流程：

原始文本 → mask_pii(text) → 脱敏文本 → LLM 抽取 → 结构化数据

↓

原始文件保留在 PostgreSQL resume_files 表
(仅用户本人可下载, 管理员无权访问原文)

实现约束:

- mask_pii() 在 backend/app/services/resume/pii_mask.py 实现, 单元测试覆盖率 ≥ 90%
- 脱敏映射表 ({placeholder: original}) 仅存于内存, 不入日志、不入数据库
- LLM 抽取完成后, [PHONE] / [EMAIL] 等占位符通过映射表回填至结构化结果
- 日志中所有简历相关字段均经脱敏, 审计日志不记录原始 PII

8.3 LLM 信息抽取

提取字段: 姓名、电话、邮箱、教育背景 (学校/专业/学历/时间)、工作经历 (公司/职位/时间/描述)、项目经验 (名称/角色/时间/技术栈)、技能列表 (熟练度)、证书

抽取 Schema (Pydantic 模型):

```
class ResumeModel(BaseModel):
    name: str = Field(..., description="姓名")
    phone: str = Field(..., pattern=r"^1[3-9]\d{9}$")
    email: str = Field(..., pattern=r"^[w\.-]+@[w\.-]+\.\w+$")
    education: list[Education]
    work_experience: list[Experience]
    skills: list[str]
    projects: list[Project]
    certifications: list[str]
```

8.4 幻觉防控

抽取后的技能点经归一化管线映射至图谱标准实体, 未匹配项标记 unmapped 走人工确认。

9. 人岗匹配算法

9.1 算法选型与评估

对主流岗位匹配算法进行系统调研与对比评估:

以基于内容的多维加权匹配为主干, 融合 Sentence-BERT 语义相似度, 规则引擎 + LLM 兜底处理非结构化字段。不采用协同过滤 (冷启动严重) 和纯深度学习 (标注数据不足)。

匹配模式: 支持两种使用场景——① **自动推荐:** 上传简历后系统自动遍历全量岗位, 计算综合评分后输出 Top-N 推荐列表 (含评分+简要对比); ② **人岗比对:** 用户从推荐列表或图谱中手动选择目标岗位, 触发详细单点比对 (含五维雷达图+差距分析+学习路径)。

9.2 画像构建与特征工程

岗位画像:

```
MATCH (p:Position {name: $name})-[r:REQUIRES]->(s:Skill)
RETURN s.name, r.necessity, r.weight
```

分组为 `must_have` (necessity=must) 和 `nice_to_have` (necessity=nice)

候选人画像：

- 技能提取：从简历解析JSON的 `skills` 字段
- 熟练度映射：精通→3，熟练/熟悉→2，了解→1，项目中使用→2
- 技能对齐：原始技能名经归一化管线映射至标准ID

统一特征向量设计：

特征类别	岗位侧	候选人侧	匹配方法
技能	must/nice + 期望熟练度 + 权重	标准 ID + 实际熟练度	布尔匹配 + 同义词集 + Embedding 余弦
经验	required_years + 行业领域	total_years + domain_experience	规则引擎 + 领域命中
学历	required_education	education_level + school_tier	层级映射 + 学校加权
项目	typical_scenarios	projects[] (名+栈+描述)	项目 Embedding 与场景余弦均值
软技能	soft_skills[]	从项目角色推断	LLM 推断兜底 (标 low_confidence , Prompt 见下方)
证书	required_certs[]	certifications[]	集合交集

Prompt 模板见源码 `backend/app/services/prompts/soft_skill_prompt.txt`。调用策略：温度 `T=0.3`，输出经 Schema 校验后写入候选人画像，`low_confidence` 字段在匹配时降权 $\times 0.5$ 。白名单由岗位本体维护共 20 项软技能。

9.3 模型训练方案

三阶段策略：M2 规则基线 (三维加权 + 100 对黄金集，目标 Spearman ≥ 0.7) → M3 语义增强 (预训练 Sentence-BERT 直接推理 + Optuna 搜索权重/阈值，目标 ≥ 0.85) → M5 后持续迭代 (Bradley-Terry 反馈学习，数据不足时退化至 Optuna 静态权重)。权重从 `configs/match_weights.json` 加载，不存在时使用默认值 `(0.6, 0.2, 0.2)`。**BT v4**：三维基础上叠加 `w_edu=0.15` (education 凸组合独立维，见 9.4)，配置文件含 `w_must/w_nice/w_exp/w_edu` 四键；旧配置无 `w_edu` 时自动按三维口径运行 (向后兼容)。

Sentence-BERT 不微调：100 对黄金集不足以微调 (通常需 1000+ 对)，仅用于评估 (Spearman) + Optuna 调阈值 (`sim_threshold`)。使用预训练模型 `paraphrase-multilingual-MiniLM-L12-v2` 直接推理

9.4 匹配计算

运行时权重 (`w_must, w_nice, w_exp`) 从 `configs/match_weights.json` 加载 (见 9.3 权重加载策略)，以下公式使用默认值作为示例。

维度	方法	默认权重	说明
必备技能	$must_score = \frac{\sum(w \times sim)}{\sum(w)}$ ， $w = \log(source_count + 1)$ ；岗位无必备技能 → null (不判分)	0.669	同义词集带权相似度映射， $\frac{\sum(w \times sim)}{\sum(w)}$ 已天然惩罚缺失；跨源多的核心技能权重更高 (方案 B)， <code>source_count</code> 默认 1 时等权退化

维度	方法	默认权重	说明
加分技能	<code>nice_score = Top-K 覆盖率 $\Sigma(w \times \text{sim}) / \Sigma(w)$, K=10 (跨源数降序取前 K)</code>	0.044	Embedding 余弦 $\geq \text{sim_threshold}$ 视为匹配; Top-K 截断抗长尾稀释; BT v3 以 Acc 验收后权重压至接近零 (nice 信号区分度低)
经验级别	规则引擎 + LLM 推断兜底	0.287	<code>required_years $\leq$ candidate</code> $\rightarrow$ 满分; <code>required_years</code> 取自 JD 抽取 <code>experience_range.min_years</code>
学历	<code>_education_score</code> : 候选层级 $\geq$ 要求 $\rightarrow$ 1.0 / 低一级 $\rightarrow$ 0.5 / 其余 $\rightarrow$ 0; 任一侧无法映射层级 $\rightarrow$ null 不判分	0.15 (<code>w_edu</code> 凸组合)	近似分 (层级映射, <code>school_tier</code> 加权待 M5); <code>required_education</code> 取自 JD 抽取 <code>education.level</code> (~57% 覆盖率); "学历不限"经 <code>_EDU_LEVELS</code> 不识别 $\rightarrow$ null 不判分

CII 通胀修正 (预处理): 在匹配计算前, 对岗位必备技能列表执行通胀修正。当 `required_count > 7` 时, 触发 CII (Capability Inflation Index) 降级——按 (`weight, source_count`) 升序排列, 将边缘必备项降级为加分技能, 避免"初级岗要求 10 年大模型经验"式的虚高要求导致匹配分虚低。

```
def apply_cii_correction(position):
    if len(position.must_skills) <= 7:
        return position # 无通胀, 直接返回
    # 按权重升序, 取最低 20% 降级为 nice
    sorted_must = sorted(position.must_skills, key=lambda s: (s.weight, s.source_count))
    demote_count = max(1, int(len(sorted_must) * 0.2))
    for skill in sorted_must[:demote_count]:
        # 保护机制: 高熟练度 + 高 source_count 的核心技能不降级
        if skill.proficiency == "专家" and skill.source_count >= 30:
            continue
        skill.necessity = 'nice' # must  $\rightarrow$  nice
    return position
```

必备技能匹配 (`must_score =  $\Sigma(w \times \text{sim}) / \Sigma(w)$ ,  $w = \log(\text{source\_count} + 1)$`): 同义词匹配采用带权相似度映射 (别名级 1.0, 语义级 0.85-1.0)。技能级权重按岗位来源源数平滑 (方案 B), 跨源多的核心必备技能命中/缺失影响更重; `source_count` 缺失或默认 1 时全技能等权 ($\log_2$), 退化为优化前行为 (黄金集零回归)。 `$\Sigma(w \times \text{sim}) / \Sigma(w)$` 已天然惩罚缺失, 无需额外比例惩罚。**岗位无必备技能时 `must_score = null` (A1 口径, 08-22)**: 无门槛岗位不再白得 `must` 维度满分贡献 (此前 `_is_must` 三重条件下 43 个在营岗位中 7 个零 `must`, 对任意候选人保底送 `w_must  $\times$  1.0`), 总分在 `nice/exp` 上权重重归一, 雷达 `must` 维度返回 `null` 不展示。

加分技能匹配 (`nice_score = Top-K 覆盖率  $\Sigma(w \times \text{sim}) / \Sigma(w)$ , K=10`): 余弦相似度, 岗位无 `nice` 时取 1.0 不扣分。聚合层 `nice` 池是全量关联技能倾倒 (实测 43 岗位 `nice` 数中位 36 / p90 271 / max 348), 全量占比口径使分数随愿望清单长度稀释 (资深前端命中 30/348 $\approx$ 0.09, 短清单岗位 4/10 = 0.4, 维度在度量清单长度而非加分项达成度)。Top-K 口径 (B1, 08-22) 只考核跨源数最高的前 10 条加分项 (`nice` 边权重统一 0.4 无区分度, 排序键用 `source_count`, 平局按 `skill_name` 升序截断保证确定性), 分数反映"岗位最想要的加分项满足几成", 与长尾规模解耦; 池不足 K 条时退化为全量口径。

软技能退出评分: `must/nice` 评分池只含技术栈技能。岗位侧软技能 (`Position.soft_skills` 属性与 `REQUIRES` 边上 `Skill.category=软技能` 的条目, 含 `must` 标注) 一律进独立通道 `PositionProfile.soft_requirements` ——不参与 `must/nice` 评分与总分, 仅供差距分析展示 (`GapSkill.is_soft` 打标, 前端徽标/软素质质量分组); 候选人侧 LLM 推断软技能的 `low_confidence  $\times$  0.5` 降权机制保留 (对显式技术技能误标同样生效)。配套口径: 学习路径生成跳过 `is_soft` 差距 (课程池为技术课, 软素质缺口命中课程属语义误配); 共享岗位缓存 schema v2 $\rightarrow$ v3 (读路径校验 `schema_revision`, 旧载荷不供)。BT 黄金集回归: v1 300 对 Acc 0.9600 / v2 384 对 Acc 0.8906 (三维口径) $\rightarrow$ **v3 384 对 BT v4 0.9714** (含 `education` 维, 见本节 BT 四维重调)。

四层主权划分：内容加权决定 must/nice 分数，Sentence-BERT 做语义扩展兜底，规则引擎处理经验/学历/证书，LLM 在画像阶段完成软技能推断——各层决策域互不重叠。

BT 四维重调 (education 进评分)：在金标 golden_set_match_v3.jsonl (384 对：岗位学历要求回填自 jd_golden_100.gold_education，候选人学历作梯度探针——正例达标/负例降两档) 上系统扫描 $w_edu \in \{0.05...0.2\}$ ，education 对 base_total 做凸组合 $base_total \times (1-w_edu) + edu_score \times w_edu$ ：

w_edu	Acc	Spearman
基线三维 (BT v3)	0.9141	0.7407
0.05	0.9505	0.7695
0.10	0.9531	0.7753
0.15 (采纳)	0.9714	0.7853
0.20	0.9714	0.7913

采纳 $w_edu=0.15$ (Acc +5.7pp / Spearman +0.045, 0.15 后 Acc 平台拐点)，configs/match_weights.json 升 **BT v4**。
向后兼容：education 无信号 (任一侧无法映射层级, "学历不限"或旧数据) 时不参与加权、维持三维口径——v2 金标 (无学历字段) 在 $w_edu=0.15$ 下 Acc 0.9141/Spear 0.7407 与 BT v3 逐位一致，旧数据零行为变更。判定线保持 0.57。

三处 JD 级画像字段错位修复 (评分输入，公式未动)：

- experience_range.min_years → required_years (此前恒 None → 经验分恒满分；全库 10769 条填充率 0)
- education.level → required_education (此前恒 None → 学历雷达维恒 null；~57% 填充)
- _EDU_LEVELS 补「初中」 (真实抽取 9 条 JD 要求初中) 配套：education_semantics_v1.jsonl (81 用例教育语义契约) 钉死 _edu_level/_education_score 防回归，契约对拍测试先行发现上述缺口。

综合评分：

```
# 1. 基础分数（无必备门槛岗位：must 不判分，权重在 nice/exp 上重归一，A1 口径）
if must_score is None:
    base_total = (nice_score * w_nice + exp_score * w_exp) / (w_nice + w_exp)
else:
    base_total = must_score * w_must + nice_score * w_nice + exp_score * w_exp

# 1b. education 第四维（BT v4）：w_edu=0.15 凸组合；
#     edu_score 无信号（任一侧无法映射层级）时跳过，维持三维口径
if w_edu is not None and w_edu > 0 and edu_score is not None:
    base_total = base_total * (1 - w_edu) + edu_score * w_edu

# 2. 判零不纳入推荐排序（前端标记 unqualified）
#     有门槛：必备技能全缺失；无门槛：加分技能 Top-K 命中率 < 20%
#     （无门槛岗位重归一后 exp 占 86.7% 权重且 req_years 常缺失，
#     唯一技能信号是 nice，前 10 条核心加分项命中不足 2 条不推荐）
if (must_total > 0 and must_score == 0) or (must_total == 0 and nice_score < 0.2):
    total = 0.0
    return total

# 3. 时效衰减（分段）
if last_updated > 365 days:
    staleness_penalty = 0.85
elif last_updated > 180 days:
    staleness_penalty = 0.95
else:
    staleness_penalty = 1.0

# 4. 最终评分（无比例惩罚，must_score 已天然惩罚缺失）
total = base_total * staleness_penalty
```

评分效果示例（默认权重 0.6/0.2/0.2，无比例惩罚）：

场景	must_score	nice_score	exp_score	base_total	final total
完美匹配	1.0	1.0	1.0	1.0	1.00
缺 1/20 must	0.95	1.0	1.0	0.97	0.97
缺 5/20 must	0.75	1.0	1.0	0.85	0.85
缺 5/5 must	0	1.0	1.0	0.40	0.00（判零）
缺 0 must，低经验	1.0	1.0	0.5	0.90	0.90

`must_score =  $\Sigma(w \times \text{sim}) / \Sigma(w)$` 已天然惩罚缺失：等权场景（source_count 默认 1）下缺 5/20 $\rightarrow$ 0.75，无需额外比例惩罚。下方示例表均基于等权场景，加权场景数值随跨源数偏移但方向不变。

时效衰减系数依据：分段衰减（180d $\rightarrow$ 0.95，365d $\rightarrow$ 0.85）基于 LinkedIn《Workforce Report》IT 技能半衰期估算，M5 后可接入 Bradley-Terry 反馈动态校准。

批量推荐逻辑（含粗筛优化）：自动匹配模式下：Step 1（粗筛）：查询 skill $\rightarrow$ position_id 倒排索引，根据候选人技能 ID 命中数降序，取 Top-K（K=200）Step 2（精算）：仅对 K 个候选岗位跑完整三维评分（含 Sentence-BERT 语义匹配）Step 3：按 total DESC 排序截取 Top-N（N 默认 10）输出：[{position_id, position_name, total_score, must_score, nice_score, exp_score, summary}]

倒排索引由聚合层每日 05:00 维护：INSERT INTO skill_position_index (skill_id, position_id) SELECT s.id, p.id FROM skills s JOIN requires r ON r.skill_id = s.id JOIN positions p ON p.id = r.position_id

缓存策略：

缓存对象	基准时长	失效条件	说明
自动推荐Top-N 结果	1h	简历或岗位聚合时间更新	检查版本号
人岗比对详细报告	24h (max)	简历或岗位聚合时间更新	随模型版本漂移
图谱全景/视图查询	300s (管理端岗位编辑/审核/归档即时失效 invalidate_graph_caches, ETL 聚合变更接受 ≤5min 滞后)	每日 05:00 版本发布	

所有缓存基于 (resume_id, position_id) 或 (resume_id) 键值，存储于 Redis，过期自动清除。

9.5 差距分析与学习路径

差距类型	条件	显示
missing	候选人不包含必备技能	红色高亮
weak	包含但熟练度不达标	黄色高亮
matched	匹配成功	绿色高亮

差距优先级：按 skill_weight DESC, gap_type (missing > weak) 排序，Top-5 作为重点改进项。

学习路径生成：对每个缺失技能，查询图谱获取先修链 → 拓扑排序 → 匹配 LEARNABLE_VIA 课程 → 输出甘特图格式 {skill, prerequisite_chain, recommended_courses[], estimated_hours, priority} 。

人岗比对模式：自动推荐列表中的每个岗位提供「详细比对」入口，点击后触发单点 BS 对比（仅需计算一个岗位 + 已缓存的候选人画像），输出完整五维雷达图 + 差距热力图 + 学习路径甘特图 + LLM 诊断报告。比对结果按缓存策略（见 9.4 节）存储。

诊断报告生成：LLM 将匹配结果 + 差距 + 路径作为 context 生成 Markdown 报告，结构：① 总体匹配度环形图 ② 三维雷达图解读 ③ 关键差距 Top-5 ④ 学习路径甘特图 ⑤ 改进建议。每条断言附带 evidence_id 可点击追溯。报告按缓存策略（见 9.4 节）存储。

9.6 评估指标

指标	目标值	评测方法
Spearman 秩相关	≥ 0.85	100 对黄金集
Top-3 推荐准确率	≥ 90%	简历查询岗位任务
差距识别准确率	≥ 85%	50 份简历差距标注
学习路径合理性	≥ 80%	30 案例专家评审
推理延迟 P95	≤ 2s	Locust 压测
用户反馈率	≥ 30%	线上统计
evidence_id 覆盖率	100%	自动校验

10. 前端可视化

10.1 技术栈

模块	技术	说明
框架	React 19 + TypeScript	函数组件 + Hooks
构建	Vite 6 + SWC	HMR热更新 + SWC编译提速
状态管理	Zustand + TanStack Query v5	6个独立store + 缓存策略
路由	React Router v7	路由守卫 + 懒加载
样式	Tailwind CSS v4 + shadcn/ui	Utility-first 组件库 + 响应式布局
2D/3D图谱	ECharts (默认) + react-force-graph-3d (可选, Three.js/WebGL)	力导向图 + 节点交互
图表	ECharts	雷达图/折线图/热力图/甘特图
测试	Vitest + @testing-library/react	组件测试

10.2 页面路由

路由	组件	说明	权限
/login	LoginPage	登录	guest
/register	RegisterPage	注册	guest
/	DashboardPage	仪表盘	全部
/graph	GraphPage	2D/3D图谱	全部
/resume-match	ResumeMatchPage	简历上传解析 + 自动匹配推荐 + 人岗比对	auth
/evolution	EvolutionPage	演化看板	guest+
/profile	ProfilePage	个人中心	auth
/admin	AdminDashboard	管理后台仪表盘	admin
/admin/users	AdminUsers	账户管理 (创建/编辑/删除/权限分配/状态管理)	admin
/admin/crawl	AdminCrawl	爬取管理 (手动触发/进度监控/历史记录)	admin
/admin/review	AdminReview	岗位审核 (查看详情/批准上线/驳回修改)	admin

10.3 图谱交互 (2D 为主, 3D 可选)

三个页签视图（所有视图在后端通过 Neo4j 查询过滤，前端仅渲染返回的数据）：

- 全景视图** (panorama)：全岗位按职能域聚合为超节点常驻（域聚合下钻），双击域展开岗位、双击岗位展开技能，附带 stats 字段告知总规模。
- 技术栈视图** (techStack)：技能为中心，边反向为技能→岗位，节点按技能频次排序。
- 岗位画像视图** (positionPortrait)：单岗位画像，薪资/经验等属性维度 + 技能要求（下拉切换岗位）。

历史视图收敛：级别视图 (level) 与岗位中心视图 (positionCenter) 页签移除——三者共用同一后端查询与数据，level 未实现本节原设计的按熟练度过滤（同数据假视图），positionCenter 的能力已被全景域聚合下钻覆盖；positionCenter 端点保留，作为岗位画像下拉岗位选项的数据源。

前端 GraphPage 按视图类型请求不同路由：

视图	路由
panorama	GET /api/v1/graph/view/panorama
techStack	GET /api/v1/graph/view/techStack
positionPortrait	GET /api/v1/graph/view/positionPortrait?position=X

数据规模控制：全景图响应 ≤ 600 节点 / 1500 边（约 $200\text{-}300\text{KB}$ ）， 2D ECharts 可保证 $60\text{fps}+$ ， 3D 模式可保证 $30\text{fps}+$ 。超限时提示用户缩小范围。视图基于 Neo4j 实时数据，panorama 端点启用 30s Redis 短 TTL 缓存用于并发合并。

T+1 与 30s TTL 的关系：每日 $05:00$ 发布新版本后，panorama 端点最多有 30s 窗口返回旧缓存数据。T+1 承诺措辞修正为「 $5:00$ 后最多 30s 内可见新数据」，明确接受这 30s 最终一致性窗口。 30s TTL 仅作用于 panorama 端点，其他图谱查询端点（position/{id}、skill/{id} 等）保留各自缓存策略（见 $11.3.5$ ）。

图谱渲染策略：默认使用 2D ECharts 力导向图（轻量、兼容性好、性能稳定）；用户可在工具栏切换至 3D 模式（react-force-graph-3d，动态加载，WebGL2 不可用时自动降级至 2D ）。 3D 模式下节点 > 200 降低力模拟计算。图谱画布占 $70\text{-}75\%$ 宽度，右侧为节点详情面板。

10.4 简历解析与匹配

页面流程：同一页面内实现简历上传/解析 → 自动岗位推荐 → 人岗比对的无缝衔接。

统一界面：页面左侧为简历上传区（拖拽/点击），上传后自动 LLM 解析 → 右侧卡片列表展示 Top-N 推荐 → 点击展开人岗比对分析报告（含环形图/雷达图/热力图/甘特图/诊断报告）。

10.5 响应式适配与移动端策略

三断点布局：桌面端（ $\geq 1025\text{px}$ ）双栏/三栏全功能（支持 $2\text{D}/3\text{D}$ 切换），平板端（ $641\text{-}1024\text{px}$ ）单栏 + 2D 图谱，移动端（ $\leq 640\text{px}$ ）纯单栏 Tab 导航 + 2D 图谱。触摸事件统一使用 onPointerDown。

10.6 用户体验设计

设计原则（对标竞赛用户体验 15 分评分标准）：

- 信息层级：**核心数据（图谱总览/匹配得分/差距 Top-5）始终可见，次要信息（证据明细/历史版本）通过点击下钻，操作路径 ≤ 3 步可达任何功能
- 操作连续：**简历上传 → 解析 → 匹配推荐 → 人岗比对全流程在同一页面内无缝闭环（/resume-match），关键帧不跳转页面
- 可视化优先：**匹配结果以环形图（总分）/雷达图（多维）/热力图（技能矩阵）/甘特图（学习路径）4 种图表展示，数据变化以颜色编码（绿升/红降/灰不变）
- 反馈及时：**耗时操作（简历解析/匹配计算）展示进度条 + 预估剩余时间；操作失败（网络/反爬/API 限流）以 Toast 提示 + 具体原因 + 重试按钮
- 错误预防：**文件上传前校验格式与大小（PDF/Word/图片 $\leq 10\text{MB}$ ），填写表单时实时校验格式，图谱切换视图时保持选中节点不丢失

11. 系统架构与部署

11.1 容器化部署

服务数变更：原方案 5 服务（api/nginx/postgres/redis/neo4j）+ 本地 Ollama 共 6 服务。考虑到 ① 本地 Ollama 已在 6.5 移除（改多 provider fallback）；② Nginx 仅做静态资源托管 + 反向代理，FastAPI 可通过 `StaticFiles` + 中间件承担。移除 Nginx 后为 **5 服务**（BE-M3-04 新增 ARQ worker），FastAPI 同端口托管前端静态资源与 API。

Docker Compose 服务列表（5 服务）：

服务	镜像	依赖	说明
api	自定义 FastAPI	postgres, redis, neo4j	后端服务 + 前端静态资源托管（StaticFiles）
postgres	pgvector/pgvector:pg15	—	关系数据库 + pgvector 向量检索扩展（一份镜像承载双能力）
redis	redis:7-alpine	—	缓存 + 限流 + ARQ 队列（db=1）
neo4j	neo4j:5	—	图数据库 + 全文索引
worker	自定义 FastAPI（同 api 镜像）	redis	ARQ 异步任务消费（爬虫/抽取/演化，BE-M3-04）

FastAPI 托管前端实现要点：

- 通过 `app.mount("/", StaticFiles(directory="frontend/dist", html=True))` 挂载前端构建产物
- API 路由前缀 `/api/v1/*` 优先匹配，未命中转 `StaticFiles`
- 中间件承担：CORS 白名单、CSP/HSTS 响应头注入、gzip 压缩
- 生产环境 TLS 由部署平台负载均衡层终止（如需本地 HTTPS，通过 `uvicorn --ssl-keyfile --ssl-certfile` 启用）

部署命令：

```
cp .env.example .env
# 编辑 .env 填写 LLM_API_KEY、JWT_SECRET_KEY 等敏感变量
docker compose up -d
# 验证健康状态
curl http://localhost:8000/health
```

环境变量：含数据库（PostgreSQL/Redis/Neo4j）、LLM 多 provider 配置（providers 列表 + 各自 `base_url/api_key/model`）、JWT（key path/expire）、告警 webhook 等配置。详见源码 `.env.example`。

11.2 安全体系

实现层变更：原方案 Nginx 承担 CSP/HSTS/CORS/gzip/TLS 等响应头与传输层安全。Nginx 移除后，这些职责由 **FastAPI 中间件** 承担，TLS 由部署平台负载均衡层终止。

安全维度	实现方案	说明
认证	JWT双Token (access 30min + refresh 7d)	RS256非对称签名
授权	RBAC权限模型	<code>graph:read</code> / <code>resume:upload</code> / <code>match:run</code> 等
限流	令牌桶 + IP级别	接口100req/min, LLM接口10req/min
脱敏	日志正则替换	身份证/手机/邮箱自动脱敏
审计	4分类审计事件	AUTH/GRAPH/DATA/ADMIN, 保留≥180天

安全维度	实现方案	说明
CORS	FastAPI CORSMiddleware 白名单模式	生产仅允许前端域名（同源时可不启用）
CSP	FastAPI 中间件注入 Content-Security-Policy 响应头	script-src / worker-src / img-src 限制
HSTS	FastAPI 中间件注入 Strict-Transport-Security	仅生产环境启用，开发环境跳过
gzip	FastAPI GZipMiddleware	响应体 > 1KB 自动压缩
TLS	部署平台负载均衡层终止	本地开发可选 uvicorn --ssl-keyfile --ssl-certfile

11.3 后端与算法集成

11.3.1 集成架构总览

后端（FastAPI）与算法模块（ backend/app/services/ ）采用同进程 Python 包调用 + ARQ 异步任务队列的混合集成模式，通过共享数据层（Neo4j / PostgreSQL + pgvector）解耦读写。

客户端请求 → FastAPI 路由层（鉴权/限流/审计）→ Service 层（同步 import 或 ARQ 异步投递）→ 算法层 / ARQ Worker → 共享数据层（Neo4j / PostgreSQL + pgvector / Redis）。

11.3.2 集成模式分类

按计算耗时与并发特征，算法调用分为三类模式：

模式	适用场景	响应时间	实现方式	示例接口
同步直接调用	轻量查询、已缓存计算	< 500ms	from algorithm.kg import crud; crud.get_position(id)	GET /api/v1/graph/position/{id}
异步任务队列	LLM 调用、批量计算	3s - 5min	ARQ 投递任务，前端轮询/SSE 获取结果	POST /api/v1/resume/parse
预计算 + 缓存	高频访问的聚合结果	< 100ms	定时任务预计算，Redis 缓存	GET /api/v1/graph/view/panorama

11.3.3 同步直接调用：Service 层 import 算法模块

职责边界：

- 算法岗负责 backend/app/services/ 包内的函数实现与单元测试。
- 后端岗负责 backend/app/services/ 中的封装层，处理鉴权、审计、缓存、异常转换。

算法模块接口规范：算法岗在 backend/app/services/ 包中实现函数，后端岗在 backend/app/services/ 中封装鉴权、缓存与异常转换。接口契约通过类型注解和文档字符串约定，详见源码 backend/app/services/kg/crud.py 与 backend/app/services/graph_service.py。

路由层调用示例：

```
GET /graph/position/{position_id} → GraphService.get_position() → crud.get_position()
```

中间经过 Redis 缓存查写、审计日志记录，最终由 backend/app/api/v1/graph.py 中 FastAPI router 注册。

11.3.4 异步任务队列：ARQ 处理耗时算法

适用场景：LLM 抽取、简历解析、批量匹配、演化计算等 > 3s 的耗时操作。

数据流： `POST /api/v1/resume/parse` → ARQ 入队 (`status=pending`) → 返回 `task_id` (202 Accepted) → ARQ Worker 消费 → 调用 `algorithm.resume.parse` → 写入结果 → 客户端轮询或 SSE 接收。任务类型包括简历解析 (3-10s)、LLM 抽取 (5s+)、演化计算 (60s+)，详见源码 `backend/app/workers/tasks.py`。

`task_status` 表结构见 11.4.1 PostgreSQL 表结构。

11.3.5 预计算与缓存策略

高频访问的聚合结果由定时任务预计算，Redis 缓存。缓存键含 `graph:panorama` (30s)、`position:{id}` (5min)、`match:cache:...` (24h)、`skill:normalize:{text}` (7d)、`search:es:{query_hash}` (10min)，写操作主动失效缓存键，下次读自动回源。

panorama 30s TTL 决策依据：原方案中 2.4.2/9.4 写「无缓存直查 Neo4j」、10.3 写「30s TTL」、本节原写「1h TTL」三处口径不一致。考虑到 T+1 更新模型下同日数据不变，30s TTL 不破坏实时性感知，统一为 30s。冷启动首次请求回源 Neo4j (P95 待 M3 初压测验证)，后续 29s 内缓存命中 < 100ms。

11.3.6 错误处理与降级策略

LLM 调用降级链（与 6.5 节一致）：多 provider 同步重试链（主讯飞 → 备 DeepSeek → 三 Qwen）+ 异步任务延迟队列重试 + 规则兜底返回 `low_confidence` 标记，前端降级展示。

算法调用异常处理（后端 Service 层统一处理）：

异常类型	HTTP 状态码	错误码	处理策略
Neo4j 连接失败	503	5001	返回降级数据或缓存
pgvector 查询超时 (> 5s)	504	5002	降级到 Neo4j 关键词搜索
LLM 调用超时 (> 30s)	504	5003	触发降级链（见上）
算法模块抛出 ValueError	400	4001	返回参数错误详情
算法模块抛出其他异常	500	5000	记录日志，返回通用错误

ARQ 任务重试策略：单 Worker 并发上限 10，超时 5min，失败重试 2 次，退避 10s。详见源码 `backend/app/workers/config.py`。

11.3.7 性能与超时控制

调用类型	超时阈值	限流	缓存
Neo4j 查询	200ms (P95)	100 req/min	Redis 5min
Neo4j 全文检索	500ms (P95)	100 req/min	Redis 10min
pgvector 向量检索	300ms (P95)	50 req/min	Redis 10min
LLM 抽取（异步）	30s/次	10 req/min/用户	不缓存
匹配计算（异步）	60s/次	5 req/min/用户	24h
演化计算（异步）	300s/次	1 req/day (定时)	1h

熔断器（基于 `circuitbreaker` 库）：连续 5 次失败触发熔断，30s 后半开试探。

11.3.8 接口契约与协作流程

前后端 + 算法三方协作流程：算法岗定义接口签名 → 后端岗封装 Service + API 并生成 OpenAPI 文档 → 前端岗基于契约 Mock 先行开发 → 三方联调 → 测试岗验证。接口变更须更新 docs/CHANGELOG.md 并在 PR 中 @相关负责人。

11.3.9 集成测试要求

测试类型	范围	工具	负责人
算法单元测试	backend/app/services/ 内函数	PyTest	张恺天
后端单元测试	Service 层 Mock 算法	PyTest + responses	马兴达
集成测试	后端 ↔ 算法 ↔ Neo4j/PostgreSQL	testcontainers	王鹏羽
契约测试	API 响应符合契约	pactman	马兴达 + 黄唐尧
E2E	全流程闭环	Playwright	王鹏羽

集成测试环境 (testcontainers)：通过 Neo4jContainer + PostgresContainer 容器化启动依赖，执行端到端断言。详见源码 backend/tests/integration/test_graph_integration.py。

11.4 数据模型设计

本节定义 PostgreSQL 关系表（含 pgvector 向量列）、Neo4j 全文索引与 Redis 键空间。Neo4j 图谱 schema 见第 5.1 节。

11.4.1 PostgreSQL 表结构

表名	用途	关键字段
users	用户账户	id, username, password(bcrypt), role, status
audit_logs	审计日志	user_id, event_type, action, detail, ip
task_status	异步任务状态	task_type, status(pending→running→succeeded/failed), progress, result_ref
resume_cache	简历解析缓存	file_path(本地卷), parsed_json(JSONB)
match_results	匹配结果	resume_id, position_id, total/must/nice/exp_score, gaps_json
match_feedback	用户反馈	match_id, score(+/-)
jd_raw	原始 JD 数据	source_platform, raw_text, structured_json, publish_time, decay_weight, confidence
skill_synonyms	技能同义词词典	standard_name, alias, confidence
graph_versions	图谱版本快照	version_tag, snapshot_json(JSONB), nodes/edges_count
rejected_changes	驳回变更记录	change_type, target_id, proposed_json, reviewer_id, reason

所有表包含 created_at / updated_at 时间戳，外键关联至 users(id)。完整 DDL 见源码 backend/migrations/。

11.4.2 Neo4j 全文索引

两个全文索引（替代原 ES 索引方案）：

- jd_index：对 Evidence 节点的 raw_text、job_title、company、city、skills 字段建立 Neo4j TEXT INDEX，使用 cjk 分词器覆盖中文搜索。
- skill_index：对 Skill 节点的名name、normalized_name、category、aliases 字段建立 TEXT INDEX。

优势：减少一个独立服务（Elasticsearch），数据一致性由 Neo4j 单一存储保证，避免 JD 入库后再同步 ES 的延迟。Cypher 通过 `db.index.fulltext.queryNodes('jd_index', $q)` 调用全文检索。

11.4.3 pgvector 向量集合 (PostgreSQL 表)

表名	维度	索引类型	度量方式	用途
skill_embeddings	384	IVFFLAT	Cosine	技能相似度检索 (Sentence-BERT MiniLM)
project_embeddings	384	IVFFLAT	Cosine	项目与岗位场景匹配
jd_embeddings	384	HNSW	Cosine	JD 语义去重辅助

索引参数：IVFFLAT `lists=100, probe=10`；HNSW `m=16, ef_construction=64`。pgvector 在数据量 < 10 万时性能与 Milvus 相当，但减少一个独立服务（Milvus + etcd + minio 依赖）。表结构：`id UUID, embedding vector(384), metadata JSONB`。

11.4.4 Redis 键空间设计

键模式	类型	TTL	用途
position:{id}	String(JSON)	5min	岗位节点缓存
match:recommend:{resume_id}	String(JSON)	1h	自动推荐 Top-N 结果
match:compare:{resume_id}:{pos_id}	String(JSON)	24h	人岗比对详细报告
rate:{ip}:{route}	String(int)	60s	令牌桶限流计数
blacklist:refresh:{token}	String	7d	登出 refresh_token 黑名单
arq:queue	List	—	ARQ 异步任务队列
task:progress:{task_id}	Hash	1h	任务实时进度

12. 账户与权限系统

12.1 角色体系

角色	权限范围
admin	全部权限（账户管理、爬取管理、岗位审核、审计日志查看）
user	图谱查看 + 简历上传 + 匹配诊断
guest	图谱只读（未登录访客）

12.2 管理后台

功能	说明
账户管理	用户 CRUD、RBAC 权限分配、启用/禁用，密码 bcrypt 加密存储
爬取管理	手动触发各平台爬取、WebSocket 实时进度推送、历史记录与异常告警

功能	说明
岗位审核	待审核列表 → 展开详情 → 批准上线/驳回修改，已审核记录追溯
岗位人工编辑	审核员可直接编辑岗位定义：技能列表增删、necessity(must/nice)切换、weight 调整 (0.0-1.0)、core_duties/scenarios 文本修改；所有改动写入 PositionEditLog 节点，附审核员 ID + 时间戳 + diff 摘要
演化审核	7.1 演化算法输出的技能新增/衰退/权重变更建议，由审核员在新岗位审核界面上确认：可接受/拒绝/修改阈值；拒绝项进入 rejected_changes 表，避免重复触发

岗位审核与人工编辑流程：审核员查看待审核列表后，可执行直接批准、驳回或人工修改（技能列表增删、权重调整、文本编辑），所有操作写入 PositionEditLog 节点支持版本回溯。

12.3 认证流程

JWT 双 Token (access 30min + refresh 7d)。**Token 存储：**access_token 与 refresh_token 均由前端内存变量维护 (access 走 Authorization: Bearer，refresh 走请求体)；refresh_token 另由后端 Set-Cookie 写入 httpOnly Cookie (httponly + samesite=lax, 生产 Secure)，用于页面刷新后经 /auth/refresh 无感恢复会话。Axios interceptor 捕获 401 自动续期（并发请求共享刷新 Promise），刷新失败清理状态并跳 /login。登出时 refresh_token 加入 Redis 黑名单 (TTL = refresh 有效期) 并清除 httpOnly Cookie。路由层通过 <AuthGuard> 组件实现鉴权与权限校验。

13. 测试与质量保障

13.1 测试金字塔

单元测试 70% (PyTest + Vitest)、集成测试 20% (API + 数据库)、E2E 10% (Playwright)。

13.2 测试覆盖

测试类型	框架	覆盖目标	阈值
后端单元	PyTest + pytest-cov	算法/路由/工具函数	≥ 60% (核心 ≥ 80%)
前端单元	Vitest + @testing-library/react	组件渲染/交互/状态	≥ 60% (核心 ≥ 80%)
API集成	FastAPI TestClient	所有端点正反用例	100% 通过
数据库集成	testcontainers	ORM/Cypher/ES查询	100% 通过
E2E	Playwright	全流程闭环	100% 通过
性能	Locust	100并发P95 < 2s	错误率 < 1%

13.3 准确率评测

评测项	黄金集规模	评测方法	目标
JD解析	100条标注	字段级对比(job_title/responsibilities/requirements/skills)；技能达标口径=词面真值对齐	≥ 90%
简历提取	50份标注	字段级对比(name/education/experience/skills/projects)	≥ 90%
人岗匹配	100个匹配对	系统匹配分 vs 人工标注分 (误差≤10分视为准确)	≥ 90%

统一评测命令：python scripts/evaluate.py --task all，输出 reports/eval_{date}.html（含分项得分+错误分析+混淆矩阵）。黄金集 JSON Lines 格式见源码 backend/tests/evaluate/evaluate.py，指标为字段级 F1 (JD/简历) 与 Spearman 秩相关 + Top-3 准确率 (人岗匹配)。

JD 解析技能达标口径：skills F1 采用「方案 A 词面真值对齐」——预测额外技能若归一化词面命中正文则豁免 FP (对"gold 精选 vs 预测全收"不对等对称)，非词面 FP 作为幻觉单列监控。110 条打样：raw F1 0.8754 → 对齐 0.9634、

幻觉 1/254 (仅"ETL")。验收判定基于对齐口径 + 3 次运行取中位 (方案 D) ; raw 精选口径与幻觉数随 skills_micro_raw / hallucinated_fp 保留供透明核对。

14. 测试用例矩阵

本矩阵覆盖系统 7 大核心能力模块的端到端验证，用例按模块分层编排。编号规则：TC-模块缩写-序号。详细执行计划见执行计划.md。

完整测试用例矩阵见 backend/tests/test_cases.md，共 49 条覆盖 DC/KG/PD/EV/RM/HL/SI 七个模块 + GRILL 治理一致性加固（索入口：docs/design/测试用例矩阵.md）。

15. 风险与应对预案

本章集中呈现项目执行期间可能面临的五类风险及其应对措施，作为各章节散落风险点的统一索引。

15.1-15.5 风险总览

类别	风险	概率	影响	应对
技术	LLM API 不可用	中	高	多 provider 同步重试链 (主讯飞→备DeepSeek→三Qwen)
技术	准确率不达标	中	高	Optuna 重搜 + 扩大黄金集
技术	Neo4j/pgvector 瓶颈	低	中	索引优化 + 参数调优
数据	爬虫被封禁	中	中	退避降频 → 官方 API → 当日停止
数据	数据质量/时滞/通胀	中-高	中	SAI/通胀检测 + 降权 + 告警
外部	API quota/反爬升级	中	中	降级公开页 + 退避 + 切换备用源
人员	单点过载/请假	中-高	高	A/B 角制 + 代码 Review + 文档完备
合规	爬虫 ToS/个人信息	中-低	高-极高	robots.txt + 脱敏 + 隔离 + PIPL/GDPR

16. 合规与伦理保障

16.1-16.4 合规与伦理总览

- 数据来源**：仅采集公开 JD/课程元数据/GitHub 数值趋势，遵循 robots.txt + 请求间隔 ≥ 8s，仅用于学术研究
- 个人信息保护**：简历数据隔离存储 + 敏感字段脱敏 + HTTPS/TLS 1.3 传输 + 审计日志 ≥ 180 天 + 支持删除权
- AI 伦理**：幻觉三道防线 + evidence_id 可追溯 + AI 内容标注 + 人工审核 + 偏见检测 (敏感词 < 5%，性别词差 < 10%) + 可解释性推理链
- 知识产权**：MIT/Apache 2.0 许可，JD 文本用于非商业学术研究，开源模型注明出处

17. 验收标准

17.1 量化目标与评分维度

指标	目标	对应维度
JD/简历/匹配准确率	均 ≥ 90%	技术创新性 + 实用价值
全流程闭环	采集→图谱→匹配→推荐	作品完整性(30分)
Docker 部署	5 服务可启动 (api/postgres/redis/neo4j/worker, FastAPI 托管前端)	作品完整性
图谱流畅度	2D 模式 ≥ 100节点@60fps, 3D 模式 ≥ 200节点@30fps	用户体验(15分)
前端响应	首屏 < 3s, 交互 < 200ms	用户体验
单元测试覆盖率	≥ 60%	作品完整性
幻觉防控	100% 实体有证据引用	技术创新性(25分)
文档完整性	全章节覆盖	提交规范

17.2 技术方案可迁移性说明

迁移维度	通用性说明	迁移成本
图谱本体模型	8 类实体 + 9 类关系不绑定特定技术领域, Position / Skill / Evidence 语义通用	零改动
数据采集管线	Scrapy 爬虫框架支持新增数据源, 仅需配置 Spider 规则与代理	低 (配置级)
清洗与去重	SimHash/MinHash/时效加权算法与领域无关	零改动
实体抽取	LLM Few-Shot + 词典后过滤通用, 需更新技能同义词词典	低 (数据级)
技能归一化	预训练 Sentence-BERT 多语言模型通用, 需更新技能白名单与同义词词典	低 (数据级)
匹配引擎	四维加权匹配 (BT v4: 技能/经验/学历) + 语义增强不依赖特定岗位领域知识	零改动
新岗位发现	Z-score 统计 + RAG 接地 + 种子列表均领域无关, 需更新种子列表	低 (数据级)
前端可视化	四视图模式 + 3D/2D 降级策略通用	零改动

迁移步骤：① 配置目标领域 Scrapy Spider → ② 更新技能同义词词典与白名单 → ③ Neo4j 重新建库 → ④ 更新新兴岗位种子列表。预计迁移周期 1-2 周。

17.3 测试数据提交规范（1 个新岗位 + 1 个既有岗位）

交付时间：M5 第 3 天 (08.28) 前完成 1 个新岗位和 1 个既有岗位的能力图谱及岗位数据源（含输入输出示例）。AI 辅助生成输入输出示例（JSON），人工校验数据准确性。

新岗位演示策略：采用双案例交付，规避 90 天数据窗口 + 12 天判定窗口的时点风险：

主交付（预置种子引导案例）：从预置 12 个新兴岗位种子中选取 1 个（如「大模型应用工程师」），M3 期间人工触发全流程产出（JD z_score 检测 → candidate → RAG 接地 → LLM 生成定义 → admin 审核 → emerging）。声明「种子为引导，岗位定义由系统 RAG + LLM 生成，非人工预置结果」。

加分项（真实自动发现案例）：M3 8/06 起跑信号检测，M4 8/16 开放 emerging 自动判定后，由系统自动产出。若 8/28 前真实案例未达 emerging，则交付 candidate 状态 + 声明「已识别但需更多数据确认，受限 90 天数据窗口」。不掩饰时点风险。

评委问答预案：若评委追问「这个新岗位是系统发现的还是人工预置的？」，主交付案例回答「种子为引导，系统完成信号检测、RAG 接地、岗位定义生成全流程；定义由 LLM 基于证据库生成，非人工撰写」；加分案例回答「完全由系统自动发现，无人工引导」。

按照赛题要求，提交测试数据必须包含 1 个新岗位和 1 个既有岗位的能力图谱及岗位数据源（含输入输出示例）。

既有岗位示例：Java 开发工程师

输入（岗位数据源）：

数据来源：BOSS直聘 + 智联招聘（90 天窗口内）
有效 JD 数量：≥ 50 条（经质量过滤）
输出格式：JSON（见 4.3 结构化输出 Schema），每条含五标字段

输出（能力图谱 + 更新说明）：

```
{
  "position_name": "Java开发工程师",
  "update_version": "2026-Q2",
  "must_have_skills": [
    {"name": "Java", "necessity": "must", "weight": 1.0, "evidence_count": 48},
    {"name": "Spring Boot", "necessity": "must", "weight": 0.95, "evidence_count": 45},
    {"name": "MySQL", "necessity": "must", "weight": 0.90, "evidence_count": 42}
  ],
  "nice_to_have_skills": [
    {"name": "Docker/K8s", "necessity": "nice", "weight": 0.70, "evidence_count": 30}
  ],
  "changes": [
    {"type": "added", "skill": "Spring AI", "evidence_refs": ["ev_boss_1203", "ev_zhilian_0456"]},
    {"type": "added", "skill": "GraalVM", "evidence_refs": ["ev_boss_0891", "ev_github_spring"]},
    {"type": "removed", "skill": "JSP/Servlet", "evidence_refs": ["ev_decline_001"]},
    {"type": "weight_up", "skill": "Docker/K8s", "old_necessity": "nice", "new_necessity": "must"}
  ],
  "update_summary": "Java开发工程师 (2026-Q2): +GraalVM, +SpringAI; -JSP/Servlet; ↑Docker(→must)"
}
```

新岗位示例：大模型应用工程师——输入为多源 JD/论文/GitHub 信号，输出含岗位名称/状态/置信度/核心职责/必备与加分技能/典型场景/证据引用/区分特征。

交付物：两个示例的完整输入输出 JSON 已按端点真实返回结构固化至 `backend/data/test_artifacts/` ——
`test_data_new_position.json`（新岗位，含 §5.1(2)④ 五字段结构化 definition）与
`test_data_existing_position.json`（既有岗位，含能力图谱 + changes 新增/删除/晋级标注 + 证据引用）。

附录：置信度阈值统一表

阈值	数值	阶段	未满足处置
数据源入图谱	≥ 0.6	4.5 交叉验证	不入生产图谱
高可靠标记	≥ 0.7	4.5 交叉验证	标记高可靠
emerging 判定	≥ 0.6	7.2.1 状态机	保持 candidate
LLM 自评	≥ 0.85	7.2.3 Z-score 门控	0.6-0.85 人工审核
岗位定义质量	≥ 0.8	7.2.5 定义生成	< 0.8 人工审核
跨源验证	≥ 2 源	6.3 幻觉防控	标记 unverified
课程质量	≥ 0.65	4.6 课程评估	不进推荐池

阈值	数值	阶段	未满足处置
抄袭判定	≥ 0.85	4.2 去重	保留最新版本
技能相似度	≥ 0.85	5.3 归一化	不自动建边